# Geoinformática

Pablo López-Ramírez

1/4/23

# Table of contents

# Prefacio

Para nosotros en CentroGeo, la computación no es sólo una herramienta para ayudarnos a resolver diferentes problemas geoespaciales; la computación es una parte integral del proceso de análisis y una forma de *pensar* en geografía. Ser capaz de programar nos permite liberarnos de los algoritmos, técnicas y configuraciones que se incluyen en el software (comercial o abierto) para el análisis de datos geográficos y pensar los problemas de forma diferente. Abrir la posibilidad de automatizar los procesos de análisis no sólo hace más eficiente nuestro trabajo, sino que también nos permite pensar en los problemas de forma diferente, de forma *computacional*. Con el fin de ayudar a nuestros estudiantes (y a estudiantes o profesionales de otras instituciones) a adquirir las herramientas técnicas básicas para poder llevar a cabo tareras de análisis de datos geoespaciales en Python o en R hemos creado este libro.

Este libro es (por lo pronto, pretende ser) una compilación de materiales educativos sobre Geoinformática. Busca funcionar como un apoyo para profesores interesados en impartir cursos relacionados con el uso de herramientas de programación para el análisis de datos geográficos o bien, para estudiantes independientes que busquen complementar su formación de manera autodidacta.



Este libro fue creado con Quarto.

Para aprender más sobre quarto, visita: https://quarto.org/docs/books.

# Introducción

Este libro es una introducción a las principales herramientas de Python y R para el Análisis Espacial, está pensado como una primera aproximación y se centra en el uso de las herramientas más que en los conceptos de análisis.

El libro busca dar a los lectores un entendimiento intuitivo de las posibilidades, limitaciones y capacidades de las herramientas geoinformáticas y su aplicación en el Análisis Espacial, sin detallar extensivamente en el transfondo matemático o teórico de los métodos estudiados. En este sentido, el curso asume que los estudiantes cuentan con nociones básicas de programación y estadística y, preferentemente, de Análisis Espacial.

Los temas elegidos fueron escogidos para brindar a los estudiantes de un panorama amplio, mas no completo, de las herramientas, tanto tecnológicas como matemáticas de la geoinformática. La idea es que, aún si no se conocen todas las técnicas y métodos existentes, los estudiantes adquieran la formación necesaria para entender los conceptos básicos, el funcionamiento general de las herramientas computacionales y sean capaces de adaptarlos a sus propios proyectos. De esta forma el curso busca establecer una base para que, en un futuro, los estudiantes investiguen más a profundidad los temas que se relacionen con sus intereses particulares.

## Organización del libro

El libro está (estará) organizado en dos grandes secciones: una dedicada a Python y otra a R. Está organizado como un conjunto de talleres. En cada taller se revisarán algunas ideas detrás del análisis de datos geoespaciales con énfasis en las herramientas y técnicas computacionales. Cada taller contiene todo el código necesario y las explicaciones básicas.

# Part I

# Geoinformática: las herramientas básicas

En esta parte del libro vamos a tratar de cubrir los fundamentos técnicos del procesaminto, análisis y visualización de datos geoespaciales con Python.

Para seguir los talleres vas a necesitar varios conjuntos de datos que puedes descargar de aqui.

El libro está desarrollado a partir de Notebooks de Jupyter, de forma que lo más natural es que vayas siguiendo el desarrollo del libro utilizando estos notebooks.

La forma más sencilla de instalar Jupyter y las librerías que estaremos utilizando es utilizando el gestor de paquetes `conda`, que nos permite instalar fácilmente paquetes de Python sin preocuparnos por dependencias del sistema.

Existen varis formas de instalar y trabajar con conda. Para usuarios de Windows quizá lo más sencillo sea instalar el paquete de cómputo científico Anaconda. Anaconda contiene, además del gestor de paquetes `conda`, muchas librerías ya preinstaladas por lo que puede resultar un poco excesivo en tamaño.

Para trabajar de mejor forma en Python es recomendable crear *environments* de trabajo. Un *environment* es algo así como una instalación independiente de Python que contiene todo lo necesario para el desarrollo de un proyecto específico. A continuación les dejo un par de tutoriales en video para aprender a trabajar con *environments* de `conda`:

Anaconda Beginners Guide for Linux and Windows - Python Working Environments Tutorial

Master the basics of Conda environments in Python

Finalmente, `conda` viene configurado por defecto para utilizar los repositorios de Anaconda, Inc.. La epmpresa provee acceso a sus repositorios sin ningún costo, sin embargo en este repositorio no siempre se encuantran las versiones más actuañlizadoas y completas que vamos a necesitar. Para evitar dificultades les recomiendo utilizar los repositorios de `conda-forge`, acá les dejo un tutorial:

Tutorial conda-forge

# 1 Transformación de datos

Las bases de datos provenientes de situaciones reales son problemáticas; contienen datos faltantes, diferentes estructuras, etcétera. En general, para analizar un conjunto de datos primero es necesario transformarlos, ya sea para corregir errores o para ajustarlos a un formato que se adapte mejor a los métodos de análisis que queremos utilizar.

Dentro del análisis de datos en general y especialmente en el análisis de datos geoespaciales, una buena parte del tiempo y esfuerzo se consume en tareras relacionadas con la limpieza y transformación de datos. Dado lo extenuantes y relevantes que son estas tareas, es sorprendente encontrar que existen muy pocas publicaciones referentes a los patrones, técnicas y buenas prácticas existentes para una eficiente limpieza, manipulación y transformación de los datos.

En este taller nos vamos a enfocar en utilizar bases de datos provenientes del mundo real para aprender cómo leerlas usando bibliotecas de Python, de modo que puedan ser transformadas y manipuladas con el fin de ser eventualmente analizadas.

El primer paso es importar todas las librerías que vamos a utilizar:

```
import os
import pandas as pd
import seaborn as sns
import numpy as np
```

- os Provee de múltiples utilidades del sistema
- pandas La librería fundamental para la transformación de datos en Python
- seaborn Herramientas para generar gráficas estadísticas
- numpy la librería básica de análisis numérico y vectorial

---

Vamos a utlizar los datos del *Censo de Poblacioń y Vivienda 2020* de INEGI. Trabajaremos con los datos a nivel AGEB para la Ciudad de México. Una AGEB se define como un *Área Geográfica ocupada por un conjunto de manzanas perfectamente delimitadas por calles, avenidas, andadores o cualquier otro rasgo de fácil identificación en el terreno y cuyo uso de suelo es principamete habitacional, industrial, de servicios, etc.*. Las AGEB's son la unidad básica de representatividad del Marco Geoestadístico Nacional, son lo suficientemente pequeñas para

representar la variabilidad espacial, pero lo suficientemente grandes para mantener la privacidad de la población y disminuir efectos de ruido estadístico.

Los datos son publicados por INEGI en un archivo en formato csv que contiene diferentes agregaciones geográficas en el mismo archivo. Para entenderlo bien, vamos a abrirlo:

> **Note**
>
> El archivo con los datos lo encuentras en la caropeta de datos del libro con el nombre `conjunto_de_datos_ageb_urbana_09_cpv2020.zip`

> **Warning**
>
> Dentro de este libro, la convención es que los datos están guardados en la carpeta `datos/` relativa al notebook que se esté ejecutando.

```
db = pd.read_csv('datos/conjunto_de_datos_ageb_urbana_09_cpv2020.zip',
                 dtype={'ENTIDAD': object,
                        'MUN':object,
                        'LOC':object,
                        'AGEB':object})
db.head()
```

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC |
|---|---|---|---|---|---|---|
| 0 | 09 | Ciudad de México | 000 | Total de la entidad Ciudad de México | 0000 | Total de la entida |
| 1 | 09 | Ciudad de México | 002 | Azcapotzalco | 0000 | Total del municip |
| 2 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total de la locali |
| 3 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urba |
| 4 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Azcapotzalco |

La librería Pandas es la que provee la funcionalidad para trabajar con datos *tabulares* en Python. La estructura fundamental de Pandas es el DataFrame, podemos pensar en los DataFrames como hojas de Excel, con columnas *nombradas* que funcionan como indices para las variables y filas para las observaciones.

Para leer el archivo utilizamos el método `read_csv()` de los DataFrames de Pandas. El parámetro `dtype` que le pasamos a la función nos asegura que ciertas columnas se lean con un tipo de datos especial, en este caso como `object`, para asegurarnos que no se lean como números y perdamos identificadores, vamos a regresar a esto más adelante.

La columna que nos interesa ahorita es `NOM_LOC`, esta nos ayuda a distinguiir los datos que vienen en cada fila: las filas etiquetadas con `Total AGEB urbana` contienen los conteos para

cada AGEB de todas las variables, entonces, nuestra primera tarea es filtrar la base y quedarnos sólo con las columnas que en la columna `NOM_LOC` dice `Total AGEB urbana`.

```
db = db.loc[db['NOM_LOC'] == 'Total AGEB urbana']
db.head()
```

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC | AGEB | MZA |
|---|---|---|---|---|---|---|---|---|
| 3 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0010 | 0 |
| 30 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0025 | 0 |
| 82 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 003A | 0 |
| 116 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0044 | 0 |
| 163 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0097 | 0 |

Lo que hicimos aquí fue utlizar el selector `loc` de pandas para seleccionar las filas que queremos, pasándole el filtro que nos interesa, en este caso `db['NOM_LOC'] == 'Total AGEB urbana'`

## 1.1 Limpieza de los datos

Hasta aquí lo que tenemos es un DataFrame con todas las variables del censo agregadas por AGEB. Ahora, para poder realizar análisis a partir de esta base de datos, necesitamos asegurarnos de que los datos son del tipo correcto, es decir, si vamos a hacer cuentas, los datos deben ser de tipo `float` o `int`. Utlicemos entonces la *propiedad* `db.dtypes` para *preguntar* los tipos de datos.

```
db.dtypes
```

```
ENTIDAD        object
NOM_ENT        object
MUN            object
NOM_MUN        object
LOC            object
                ...
VPH_CVJ        object
VPH_SINRTV     object
VPH_SINLTC     object
VPH_SINCINT    object
VPH_SINTIC     object
Length: 230, dtype: object
```

Como podemos ver, no sólo las columnas que pedimos que leyera como `object` las leyó así, también las demás columnas. Esto se puede deber a que tienen codificados valores faltantes con caracteres especiales, por lo que pandas no pudo convertirlos automáticamente en números.

Para entender esto un poco mejor, vamos a leer el diccionario de datos del censo.

> **Note**
>
> También pueden explorar el archivo en excel, para verlo con más calma

```
diccionario = pd.read_csv('datos/diccionario_datos_ageb_urbana_09_cpv2020.csv', skiprows=3
diccionario
```

| | Núm. | Indicador | Descripción |
|---|---|---|---|
| 0 | 1 | Clave de entidad federativa | Código que identifica a la entidad federativa |
| 1 | 2 | Entidad federativa | Nombre oficial de la entidad federativa. |
| 2 | 3 | Clave de municipio o demarcación territorial | Código que identifica al municipio o demarc |
| 3 | 4 | Municipio o demarcación territorial | Nombre oficial del municipio o demarcación |
| 4 | 5 | Clave de localidad | Código que identifica a la localidad al interi |
| ... | ... | ... | ... |
| 225 | 218 | Viviendas particulares habitadas que disponen ... | Viviendas particulares habitadas que tienen |
| 226 | 219 | Viviendas particulares habitadas sin radio ni ... | Viviendas particulares habitadas que no cue |
| 227 | 220 | Viviendas particulares habitadas sin línea tel... | Viviendas particulares habitadas que no cue |
| 228 | 221 | Viviendas particulares habitadas sin computado... | Viviendas particulares habitadas que no cue |
| 229 | 222 | Viviendas particulares habitadas sin tecnologí... | Viviendas particulares habitadas que no cue |

> **Warning**
>
> Fíjense como pasamos `skiprows=3` para leer el diccionario del censo. Esto le dice a pandas que el header (los nombres de las columnas), vienen en el cuarto renglón.

A partir de este diccionario podemos ver que hay varias formas de codificar valores faltantes: '999999999', '99999999', '*' y 'N/D'.

Para poder convertir todas estas columnas en numéricas tenemos que reemplazar todos esos valores por la forma en la que se expresan los datos faltantes en Pandas, utilizando el valor *Not a Number* de numpy. Para hacer este reemplazo vamos a usar la función `replace` de Pandas, que toma como argumento el valor que queremos reemplazar y el valor por el cual lo queremos reemplazar:

```
db = (db
      .replace('999999999', np.nan)
      .replace('99999999', np.nan)
      .replace('*', np.nan)
      .replace('N/D', np.nan))
```

¡Esta fue una instrucción complicada!

Pero no es realmente difícil. Como hemos visto hasta aquí, los métodos de los DataFrames en general regresan otros DataFrames con el resultado de la operación, esto nos permite *encadenar* métodos, de forma que cuando hacemos `db..replace('999999999', np.nan)..replace('99999999', np.nan)`, el segundo `replace` opera sobre el resultado del primero y así sucesivamente. Este encadenamiento de métodos nos ayuda a escribir código más fácil de leer.

Ahora ya tenemos todos los valores faltantes codificados adecuadamente, sin embargo aún nos falta convertirlos a números ¿verdad?

```
db.dtypes
```

```
ENTIDAD        object
NOM_ENT        object
MUN            object
NOM_MUN        object
LOC            object
                ...
VPH_CVJ        object
VPH_SINRTV     object
VPH_SINLTC     object
VPH_SINCINT    object
VPH_SINTIC     object
Length: 230, dtype: object
```

La forma normal de cambiar el tipo de datos de una columna es utilizar el método `astype`

```
db['VPH_CVJ'].astype('float').dtypes
```

```
dtype('float64')
```

> **Note**
>
> Aquí no estamos asignando el resultado de la operación a ninguna variable, el resultado de esta operación no modifica el valor de los datos.

Así podríamos ir cambiando columna por columna, pero como estamos programando ¡nos gusta hacer las cosas en bruto!

En el diccionario de datos tenemos los nombres de todas las variables, entonces podemos utilizar estos nombres para seleccionar todas las columnas que contienen datos numéricos y cambiar su tipo en el DataFrame. Fíjense que las primeras 8 filas del diccionario contienen los identificadores geográficos:

```
diccionario.head(8)
```

| | Núm. | Indicador | Descripción |
|---|---|---|---|
| 0 | 1 | Clave de entidad federativa | Código que identifica a la entidad federativa.... |
| 1 | 2 | Entidad federativa | Nombre oficial de la entidad federativa. |
| 2 | 3 | Clave de municipio o demarcación territorial | Código que identifica al municipio o demarcaci... |
| 3 | 4 | Municipio o demarcación territorial | Nombre oficial del municipio o demarcación ter... |
| 4 | 5 | Clave de localidad | Código que identifica a la localidad al interi... |
| 5 | 6 | Localidad | Nombre con el que se reconoce a la localidad d... |
| 6 | 7 | Clave del AGEB | Clave que identifica al AGEB urbana, al interi... |
| 7 | 8 | Clave de manzana | Clave que identifica a la manzana, al interior... |

Las demás filas contienen los nombres (y descripciones) de las variables del Censo.

```
campos_datos = diccionario.loc[8:,]['Mnemónico']
campos_datos
```

```
8           POBTOT
9           POBFEM
10          POBMAS
11           P_0A2
12          P_0A2_F
           ...
225         VPH_CVJ
226      VPH_SINRTV
227      VPH_SINLTC
228     VPH_SINCINT
```

```
229     VPH_SINTIC
Name: Mnemónico, Length: 222, dtype: object
```

Aquí utilizamos una vez más el método `loc` para seleccionar filas en nuestros datos. En esta ocasión seleccionamos las filas por *índice* (en este momento nuestro índice es simplemente el número de fila, más adelante usaremos índices diferentes), la selección `loc[8:,]` simplemente quiere decir *todas las columnas para las filas de la 9 en adelante*.

También estamos seleccionando una única columna al hacer `['Mnemónico']`, el resultado de esta selección ya no es un DataFrame, es una Serie. Las series son las estructuras que usa Pandas para guardar una sóla columna (o fila).

Las Series se pueden utilizar (igual que las listas) para seleccionar columnas de un DataFrame, entoinces, ahora sí podemos cambiar todos los tipos de datos de una sola vez.

```
db[campos_datos] = db[campos_datos].astype('float')
db.dtypes
```

```
ENTIDAD         object
NOM_ENT         object
MUN             object
NOM_MUN         object
LOC             object
                ...
VPH_CVJ        float64
VPH_SINRTV     float64
VPH_SINLTC     float64
VPH_SINCINT    float64
VPH_SINTIC     float64
Length: 230, dtype: object
```

## 1.2 Descripciones de los datos

Pandas nos provee una serie de métodos para obtener descripciones generales de la tabla. Podemos usar el método `info` para obtener una descripción general de la estructura de la tabla y el espacio que ocupa en la memoria:

```
db.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 2433 entries, 3 to 68915
Columns: 230 entries, ENTIDAD to VPH_SINTIC
dtypes: float64(222), int64(1), object(7)
memory usage: 4.3+ MB
```

Para obtener las estadísticas descriptivas podemos usar el método `describe`:

```
db.describe()
```

| | MZA | POBTOT | POBFEM | POBMAS | P_0A2 | P_0A2_F | P_0A2_M | P_3 |
|---|---|---|---|---|---|---|---|---|
| count | 2433.0 | 2433.000000 | 2422.000000 | 2423.00000 | 2406.000000 | 2392.000000 | 2390.000000 | 2423 |
| mean | 0.0 | 3758.993835 | 1970.647812 | 1804.64837 | 109.901912 | 54.471990 | 56.089121 | 3661 |
| std | 0.0 | 2433.068753 | 1254.533102 | 1186.95856 | 85.636899 | 42.286817 | 43.908616 | 2347 |
| min | 0.0 | 0.000000 | 0.000000 | 0.00000 | 0.000000 | 0.000000 | 0.000000 | 0.00 |
| 25% | 0.0 | 2045.000000 | 1083.500000 | 974.00000 | 46.250000 | 23.000000 | 24.000000 | 2018 |
| 50% | 0.0 | 3396.000000 | 1783.500000 | 1616.00000 | 91.000000 | 45.000000 | 46.000000 | 3304 |
| 75% | 0.0 | 4992.000000 | 2617.500000 | 2391.00000 | 152.000000 | 75.000000 | 77.000000 | 4852 |
| max | 0.0 | 21198.000000 | 11128.000000 | 10616.00000 | 709.000000 | 350.000000 | 393.000000 | 2053 |

## 1.3 Creación de variables

Muchas veces vamos a querer crear nuevas columnas a partir de las ya existentes. Por ejemplo, podemos estar interesados en el porcentaje de población femenina en cada AGEB.

```
pct_fem = db['POBFEM'] / db['POBTOT']
pct_fem.head()
```

```
3      0.532516
30     0.521187
82     0.527037
116    0.535025
163    0.512408
dtype: float64
```

Fíjense cómo usamos `/` para dividir dos columnas. El resultado de la operación lo guardamos en la variable `pct_fem` ¿De qué tipo será esta variable?

```
pct_fem.info()
```

```
<class 'pandas.core.series.Series'>
Int64Index: 2433 entries, 3 to 68915
Series name: None
Non-Null Count  Dtype
--------------  -----
2405 non-null   float64
dtypes: float64(1)
memory usage: 38.0 KB
```

Es una serie, es decir una columna en nuestro caso. Como esta columna comparte el mismo *índice* que los datos originales (es resultado de una operación renglón por renglón), entonces la podemos agregar al DataFrame original facilmente:

```
db['pct_fem'] = pct_fem
db['pct_fem'].head()
```

```
/tmp/ipykernel_5237/2610780181.py:1: PerformanceWarning: DataFrame is highly fragmented.  Th
  db['pct_fem'] = pct_fem
```

```
3      0.532516
30     0.521187
82     0.527037
116    0.535025
163    0.512408
Name: pct_fem, dtype: float64
```

### 1.3.1 Modificar valores

De la misma forma que podemos agregar columnas (o filas) a nuestro DataFrame, podemos también modificar los valores existentes. Para explorar esto, vamos a crear una nueva columna y llenarla con valores *nulos*:

```
# Nueva columna llena de sólamente el número 1
db['Nueva'] = None
db['Nueva'].head()
```

```
/tmp/ipykernel_5237/463547730.py:2: PerformanceWarning: DataFrame is highly fragmented.  This
  db['Nueva'] = None
```

```
3      None
30     None
82     None
116    None
163    None
Name: Nueva, dtype: object
```

Podemos fácilmente cambiar los valores de todas las filas:

```
db['Nueva'] = 1
db['Nueva'].head()
```

```
3      1
30     1
82     1
116    1
163    1
Name: Nueva, dtype: int64
```

O también cambiar el valor sólo para una fila específica:

```
db.loc[3, 'Nueva'] = 10
db['Nueva'].head()
```

```
3      10
30      1
82      1
116     1
163     1
Name: Nueva, dtype: int64
```

### 1.3.2 Eliminar columnas

Eliminar columnas es igualmente fácil usando el método `drop`:

```
db = db.drop(columns=['Nueva'])
'Nueva' in db.columns
```

```
False
```

¡Fíjense como *preguntamos* al final si ya habíamos eliminado la columna!

### 1.3.3 Buscando datos

Muchas veces queremos encontrar *observaciones* que cumplan con uno o más criterios. Una vez más, el método `loc` es nuestro amigop para seleccionar datos. Supongamos que queremos encontrar aquelas AGEBs que tengan una población de '65 años o más' mayor a 1,000 personas.

```
db_seleccion = db.loc[db['POB65_MAS'] > 1000, :]
db_seleccion.head()
```

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC | AGEB | MZA |
|---|---|---|---|---|---|---|---|---|
| 30 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0025 | 0 |
| 444 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0186 | 0 |
| 3617 | 09 | Ciudad de México | 003 | Coyoacán | 0001 | Total AGEB urbana | 0107 | 0 |
| 4075 | 09 | Ciudad de México | 003 | Coyoacán | 0001 | Total AGEB urbana | 0287 | 0 |
| 4886 | 09 | Ciudad de México | 003 | Coyoacán | 0001 | Total AGEB urbana | 0573 | 0 |

Simplemente pasamos la *condición* que nos interesa al selector y listo.

Los criterios de búsquera pueden ser tan sofisticados como se requiera, por ejemplo, podemos seleccionar los AGEBs en los cuales la población de 0 a 14 años sea menor a un cuarto de la población total:

```
db_seleccion = db.loc[(db['POB0_14'] / db['POBTOT']) < 0.25, :]
db_seleccion.head()
```

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC | AGEB | MZA |
|---|---|---|---|---|---|---|---|---|
| 3 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0010 | 0 |
| 30 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0025 | 0 |
| 82 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 003A | 0 |
| 116 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0044 | 0 |

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC | AGEB | MZA |
|---|---|---|---|---|---|---|---|---|
| 163 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0097 | 0 |

Podemos hacer combinaciones arbitrarias de selectores utilizando los operadores lógicos `&` (and) y `|` (or). Por ejemplo, podemos combinar nuestras selecciones anteriores para encontrar las AGEBs con menos de 50% de mujeres y población de 0 a 14 años sea menor a un cuarto de la población total

```
db_seleccion = db.loc[(db['pct_fem'] < 0.5) &
                      ((db['POB0_14'] / db['POBTOT']) < 0.25), :]
db_seleccion.head()
```

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC | AGEB | MZA |
|---|---|---|---|---|---|---|---|---|
| 2342 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0877 | 0 |
| 3292 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 1165 | 0 |
| 5321 | 09 | Ciudad de México | 003 | Coyoacán | 0001 | Total AGEB urbana | 0770 | 0 |
| 6016 | 09 | Ciudad de México | 003 | Coyoacán | 0001 | Total AGEB urbana | 1092 | 0 |
| 7919 | 09 | Ciudad de México | 003 | Coyoacán | 0001 | Total AGEB urbana | 1660 | 0 |

## 1.4 Ordenar valores

Finalmente, vamos a ver cómo ordenar los datos de acuerdo a los valores de un campo. Pensemos que queremos ver las 10 AGEBS más pobladas de la ciudad.

```
db.sort_values('POBTOT', ascending = False).head(10)
```

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC | AGE |
|---|---|---|---|---|---|---|---|
| 39932 | 09 | Ciudad de México | 010 | Álvaro Obregón | 0001 | Total AGEB urbana | 0135 |
| 63316 | 09 | Ciudad de México | 016 | Miguel Hidalgo | 0001 | Total AGEB urbana | 0444 |
| 65102 | 09 | Ciudad de México | 016 | Miguel Hidalgo | 0001 | Total AGEB urbana | 1349 |
| 9394 | 09 | Ciudad de México | 004 | Cuajimalpa de Morelos | 0020 | Total AGEB urbana | 0316 |
| 9090 | 09 | Ciudad de México | 004 | Cuajimalpa de Morelos | 0001 | Total AGEB urbana | 0369 |
| 9190 | 09 | Ciudad de México | 004 | Cuajimalpa de Morelos | 0001 | Total AGEB urbana | 0373 |
| 6211 | 09 | Ciudad de México | 003 | Coyoacán | 0001 | Total AGEB urbana | 1162 |
| 52537 | 09 | Ciudad de México | 012 | Tlalpan | 0001 | Total AGEB urbana | 2121 |
| 26177 | 09 | Ciudad de México | 007 | Iztapalapa | 0001 | Total AGEB urbana | 1994 |
| 42074 | 09 | Ciudad de México | 010 | Álvaro Obregón | 0001 | Total AGEB urbana | 1171 |

El método `sort_values` nos permite ordenar los datos de acuerdo al valor (o criterio) que queramos. El argumento `ascending = False` indica que los queremos ordenar de forma descendente.

## 1.5 Exploración Visual

Ya que nos empezamos a familiarizar con el manejo de datos usando Pandas, podemos empezar a hacer cosas más divertidas, por ejemplo, explorar visualmente los datos.

La librería `seaborn` nos ofrece una serie de herramientas para la exploración visual de los datos. Podemos comenzar con un histograma para ver la distribución de los valores de una columna.

```
_ = sns.histplot(db['POBTOT'], kde = False)
```

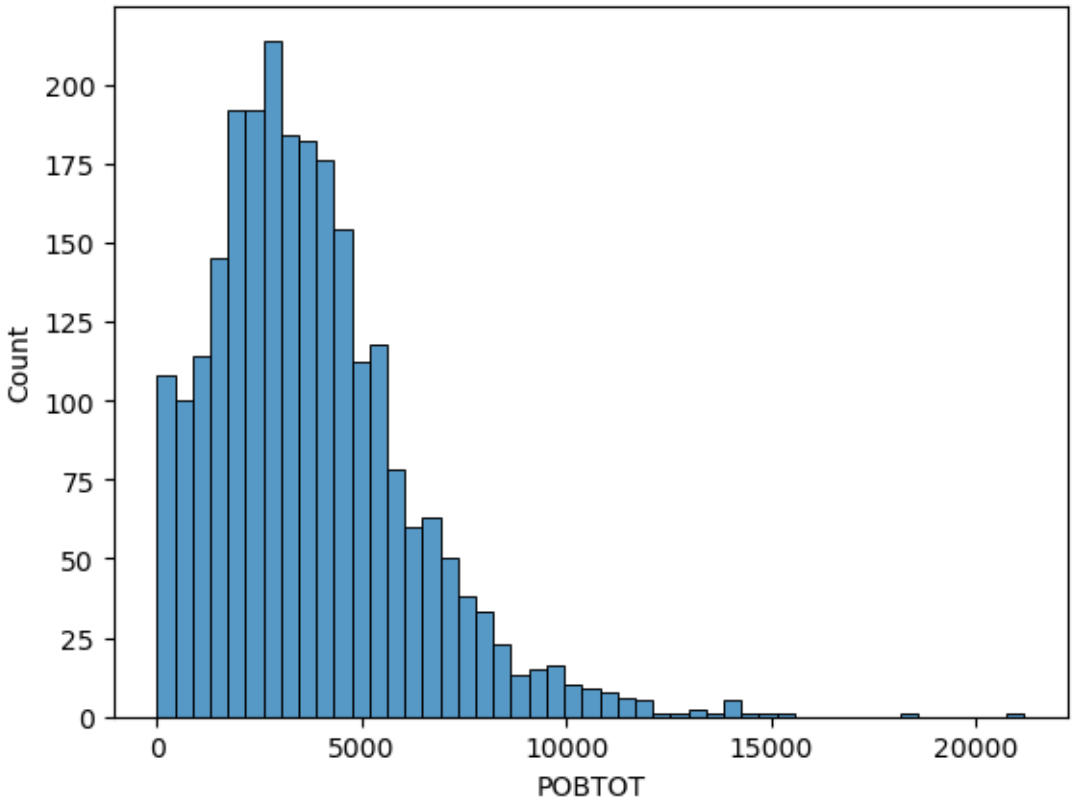


La función `histplot` de seaborn nos regresa el histograma, el argumento `kde=False` le dice que no queremos que ajuste una distribución empírica.

> **Note**
>
> Cuando hicimos `_ = sns.histplot(db['POBTOT'], kde = False)` estamos asignando el resultado a la variable `_`, esto se hace comunmente cuando no queremos ya hacer nada más con ese resultado. Más adelante haremos operaciones sobre las gráficas.

#### 1.5.0.1 Densidad de Kernel

Otra forma de representar la distribución de una variable es ajustando una *densidad de kernel*, que estima una distribución (empírica) de probabilidad a partir de nuestras observaciones.

```
_ = sns.kdeplot(db['POBTOT'], fill = True)
```

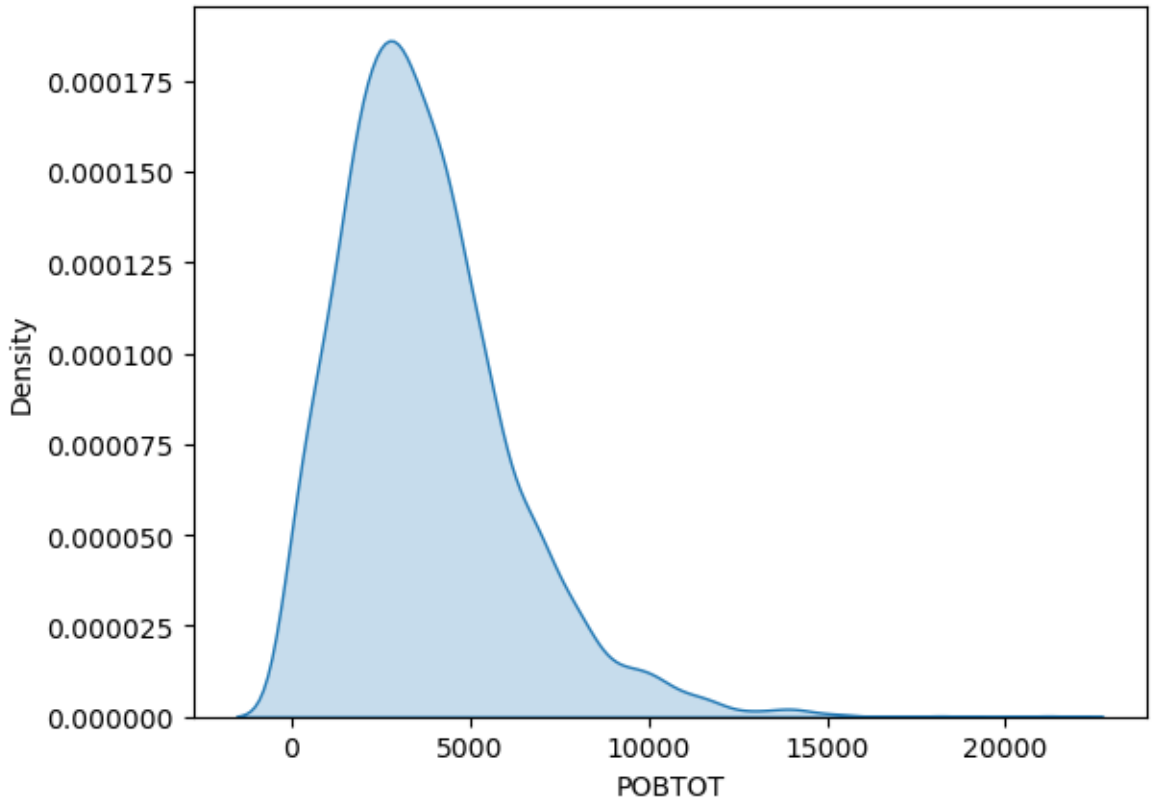


Otra visualización muy útil es la de la *distribución conjunta* de dos variables. Por ejemplo, supongamos que queremos comparar las distribuciones de la población masculina y femenina.

```
_ = sns.jointplot(data=db, x='POBFEM', y='POBMAS')
```

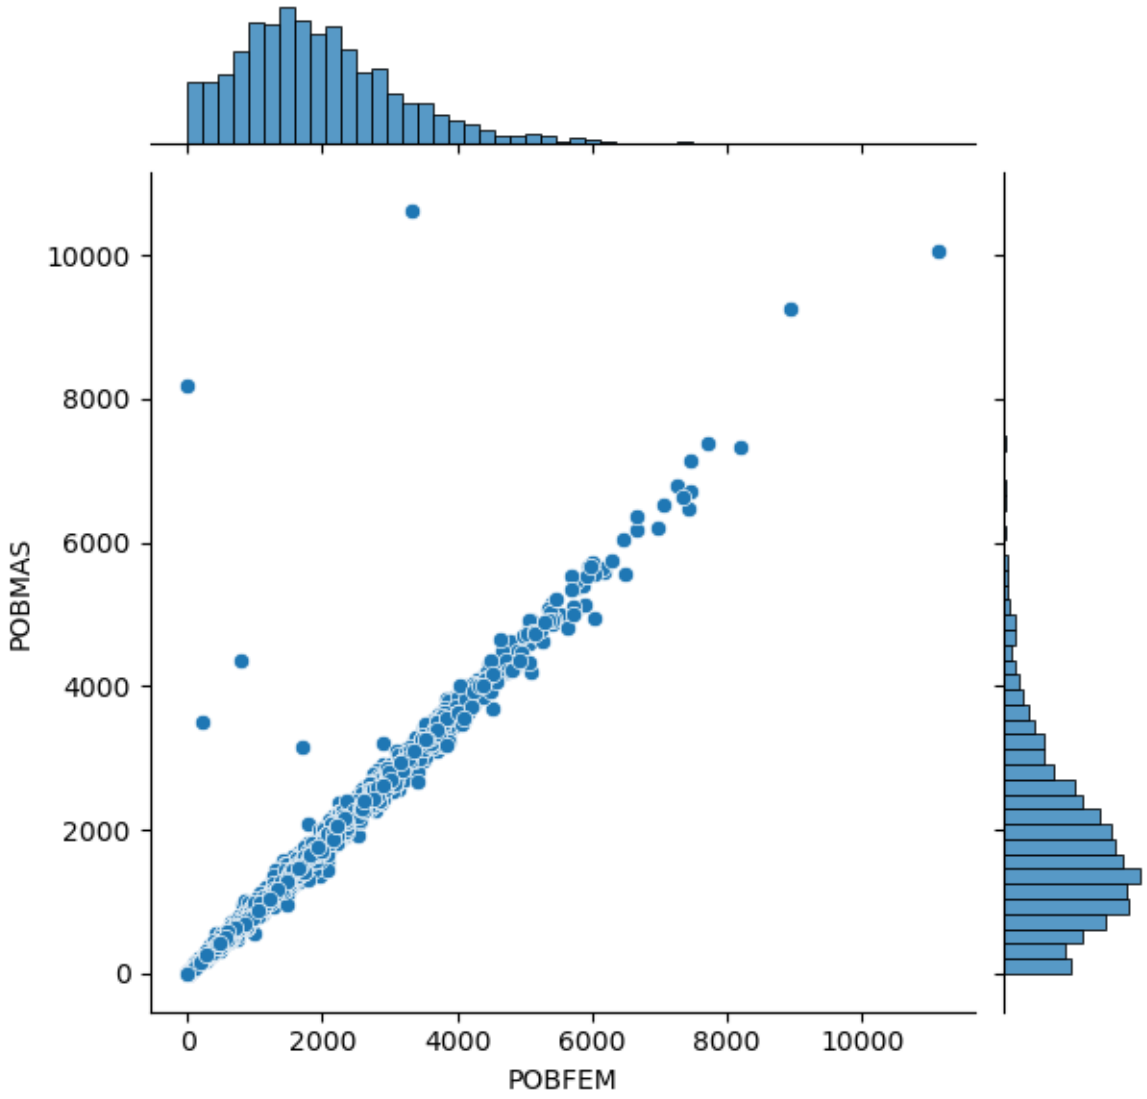


La relación, como es de esperarse, es casi perfectamente lineal, pero ver las distribuciones conjuntas nos permite identificar algunas AGEBS con poblaciones masculinas desproporcionadamente grandes ¿Qué serán?.

Muchas veces queremos visualizar la distribución conjunta de varias variables al mismo tiempo. Por ejemplo cuando queremos hacer ejercicios de regresión queremos explorar la correlación entre las covariables. Una forma de visualizar rápidamente estas distribuciones conjuntas es

con un PairGrid. Utlicemos uno sencillo para ver las distribuciones de algunas variables.

```
vars = ['P_0A2', 'P_15A17', 'PNACOE', 'P3YM_HLI']
g = sns.PairGrid(db[vars])
g = g.map(sns.scatterplot)
```

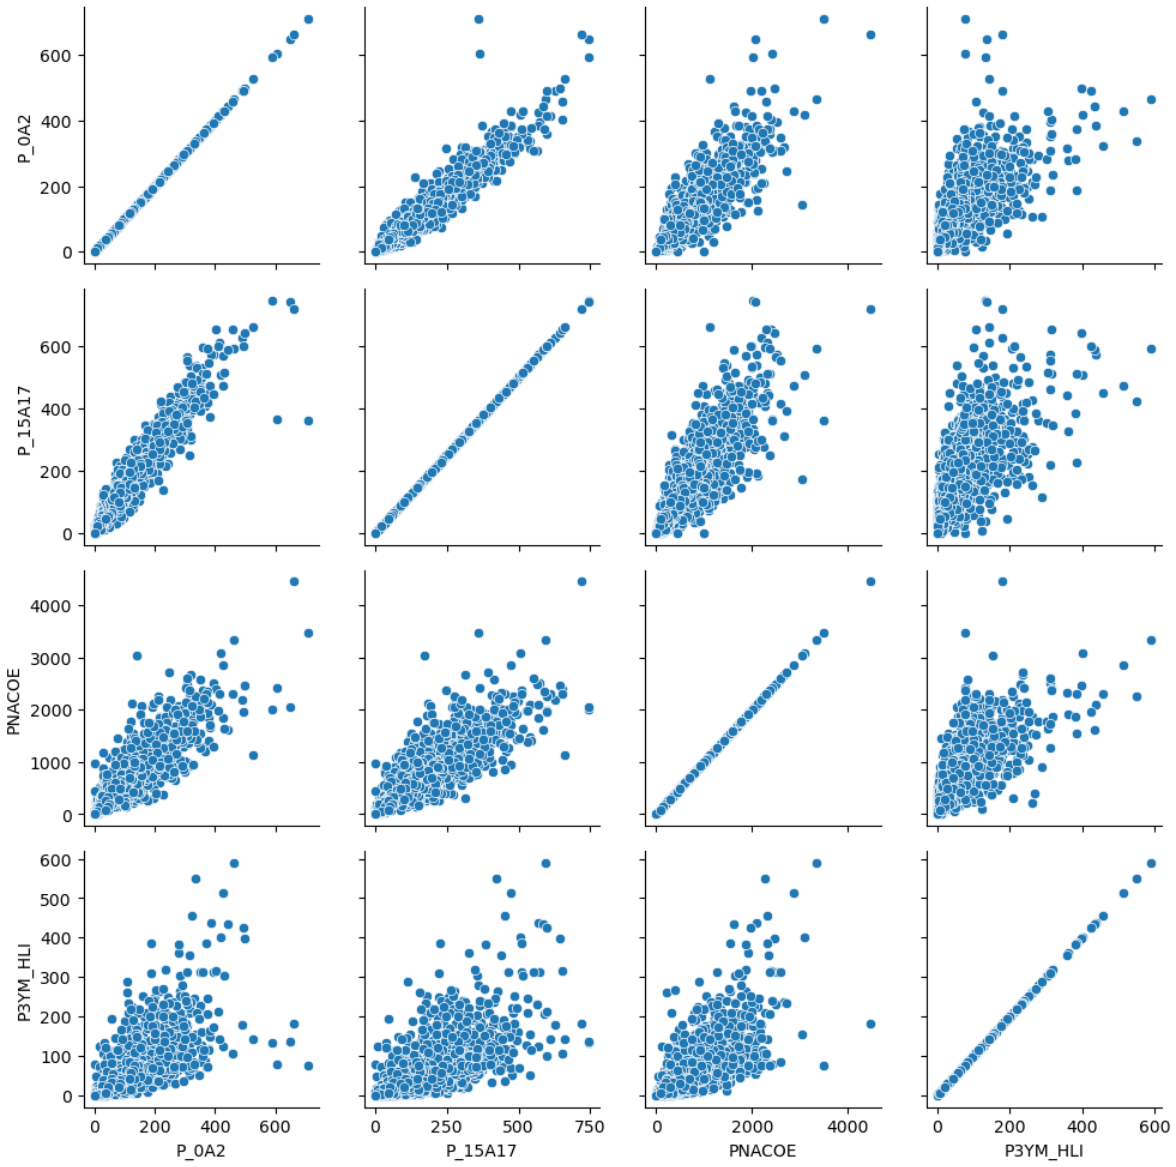


La función `PairPlot` sólo nos prepara la malla (un cuadrado del número de variables de los datos) y con el `map` llenamos esa malla con la gráfica que queramos, en nuestro caso un

diagrama de dispersión.

En este caso la diagonal no es muy informativa, es un diagrama de dispersión de una variable consigo misma. `PairPlot` es muy flexible y nos permite *mapear* diferentes funciones para la diagonal y los demás elementos, por ejemplo:

```
g = sns.PairGrid(db[vars])
g.map_diag(sns.histplot)
g.map_offdiag(sns.scatterplot)
```

```
<seaborn.axisgrid.PairGrid at 0x7f70a19c4040>
```

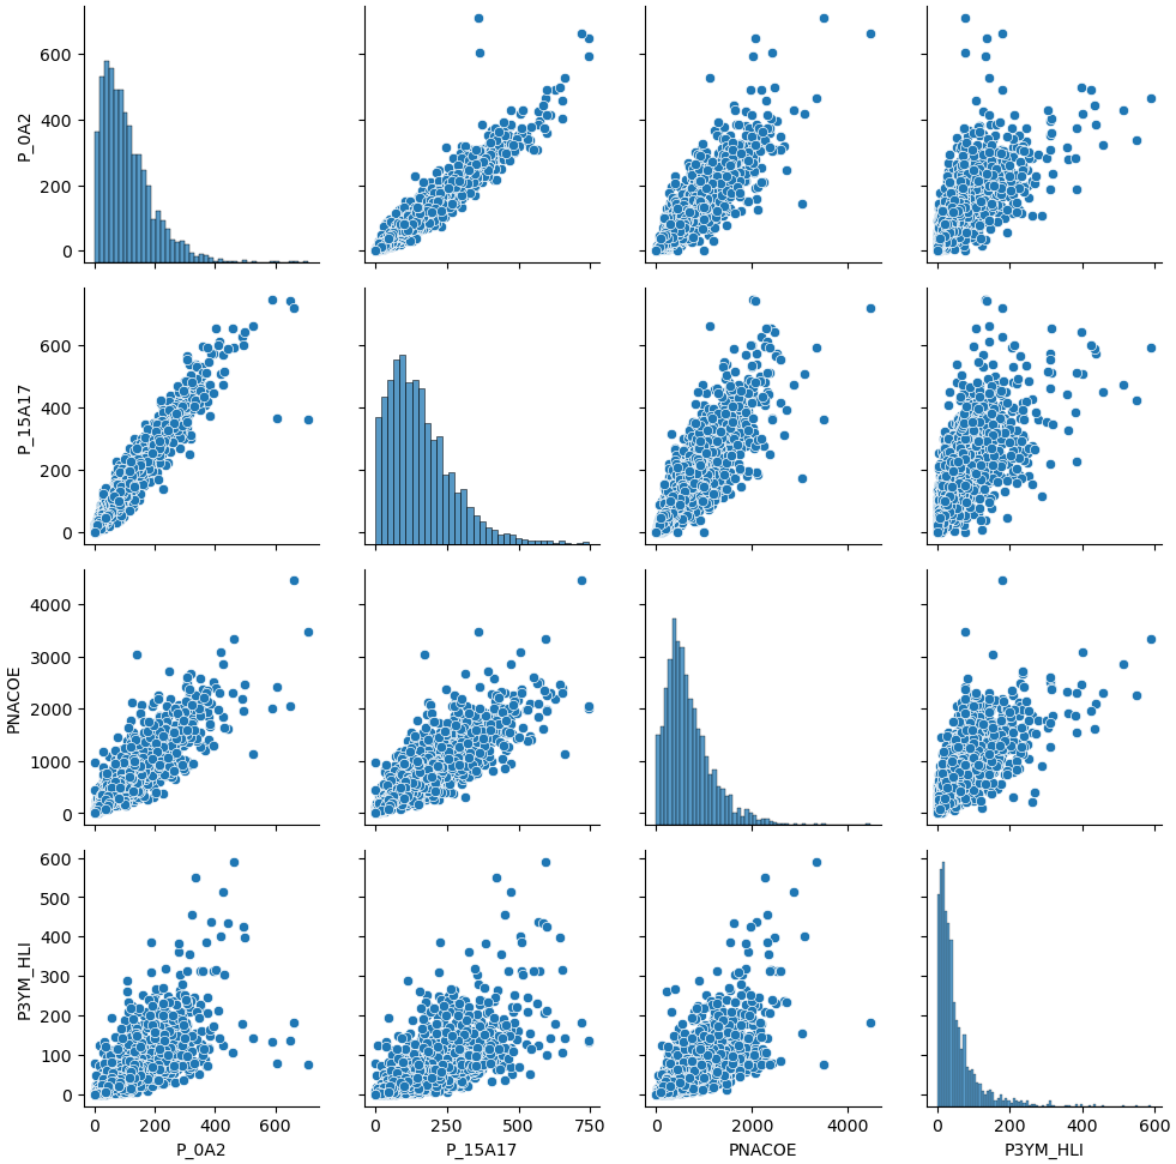


## 1.6 Organizando los datos

Muchos flujos de análisis requieren organizar los datos en una estructura particular conocida como *Tidy Data* (algo así como *datos ordenados*). La idea es tener una estructura estandarizada con principios comunes de manipulación que sirva como entrada a diferentes tipos de análisis.

Las tres características fundamentales de un conjunto de datos *bien ordenado* de acuerdo a los principios *tidy* son:

1. Cada variable en una columna
2. Cada observación en una fila
3. Cada unidad de observación en una tabla

Para mayor información sobre el concepto de *Tidy Data*, puede consultarse el Artículo Académico original (de Acceso Libre), así como el Repositorio Púlico asociado a él.

Tratemos de aplicar el concepto de *Tidy Data* a los datos de la práctica. Primero, recordando su estructura:

```
db.head()
```

| | ENTIDAD | NOM_ENT | MUN | NOM_MUN | LOC | NOM_LOC | AGEB | MZA |
|---|---|---|---|---|---|---|---|---|
| 3 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0010 | 0 |
| 30 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0025 | 0 |
| 82 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 003A | 0 |
| 116 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0044 | 0 |
| 163 | 09 | Ciudad de México | 002 | Azcapotzalco | 0001 | Total AGEB urbana | 0097 | 0 |

Esta base de datos no cumple con las características *tidy*. En efecto, tenemos las variables en columnas (sin contar los identificadores), pero:

- Tenemos dos tipos de unidades: personas y viviendas. El principio *tidy* nos indica que necesitamos dos tablas para representar los datos.
- Para cada tipoi de unidad tenemos en la misma fila tantas *observaciones* como variables (del mismo tipo). Por ejemplo, el valor de la población para cada grupo de edad en cada AGEB es una observación.

Entonces, vamos a trabajar en acomodar la tabla a los principios *tidy*. Para comenzar, trabajemos sólo con las variables que representan segmentos de edad de la población. Seleccionar sólo estas columnas puede ser engorroso, pero si nos fijamos en el diccionario, podemos observar que todas las variables que nos interesan empiezan con 'P_' Podemos usar esta observación para seleccionar, a partir de la lista de columnas, sólo las que nos interesan:

```
cols_pob = [c for c in db.columns if c.startswith('P_')]
print(cols_pob)
```

```
['P_0A2', 'P_0A2_F', 'P_0A2_M', 'P_3YMAS', 'P_3YMAS_F', 'P_3YMAS_M', 'P_5YMAS', 'P_5YMAS_F',
```

Ahora, vamos a construir un identificador único de AGEB para cada fila concatenando los identificadores de entidad, municipio, localidad y ageb:

```
db['AGEB_cvgeo'] = db['ENTIDAD'] + db['MUN'] + db['LOC'] + db['AGEB']
db['AGEB_cvgeo'].head()
```

```
3      0900200010010
30     0900200010025
82     090020001003A
116    0900200010044
163    0900200010097
Name: AGEB_cvgeo, dtype: object
```

Ya con este identificador, podemos eliminar de la tabla los identificadores que usamos para construirlo

```
db = db.drop(columns=['ENTIDAD', 'MUN', 'LOC', 'AGEB'])
```

Copiamos las columnas que nos interesan a una nueva tabla

```
rangos = db[['AGEB_cvgeo'] + cols_pob]
rangos.head()
```

| | AGEB_cvgeo | P_0A2 | P_0A2_F | P_0A2_M | P_3YMAS | P_3YMAS_F | P_3YMAS_M | P_ |
|---|---|---|---|---|---|---|---|---|
| 3 | 0900200010010 | 60.0 | 32.0 | 28.0 | 3123.0 | 1663.0 | 1460.0 | 30 |
| 30 | 0900200010025 | 122.0 | 58.0 | 64.0 | 5470.0 | 2856.0 | 2614.0 | 53 |
| 82 | 090020001003A | 88.0 | 49.0 | 39.0 | 4147.0 | 2183.0 | 1964.0 | 40 |
| 116 | 0900200010044 | 110.0 | 49.0 | 61.0 | 4658.0 | 2502.0 | 2156.0 | 45 |
| 163 | 0900200010097 | 40.0 | 16.0 | 24.0 | 2136.0 | 1099.0 | 1037.0 | 21 |

Ahora vamos a reorganizar la tabla de forma que cada grupo de edad corresponda a una fila en lugar de una columna, de esta forma tenemos las observaciones en filas, de acuerdo al principio *tidy*.

Para lograr esto lo que tenemos que hacer es la operación inversa de un pivote, es decir, un *stack*. El método `stack` hace justo lo que necesitamos, sólo tenemos que especificar el índice (lo que distingue a cada observación) que queremos utilizar para cada fila, en este caso `AGEB_cvgeo`.

```
rangos = rangos.set_index('AGEB_cvgeo').stack()
rangos
```

```
AGEB_cvgeo
0900200010010  P_0A2           60.0
               P_0A2_F         32.0
               P_0A2_M         28.0
               P_3YMAS       3123.0
               P_3YMAS_F     1663.0
                              ...
0901700011524  P_18A24_M       230.0
               P_15A49_F      1111.0
               P_60YMAS        706.0
               P_60YMAS_F      394.0
               P_60YMAS_M      312.0
Length: 96555, dtype: float64
```

Perfecto, eso se parece bastante a lo que buscamos, sólo que en lugar de un DataFrame lo que tenemos es una Serie. Fíjense que para cada valor del índice (`AGEB_cvgeo`), tenemos todos los valores de los grupos de población.

Para convertir esto en un DataFrame lo más sencillo es quitar el índice que creamos con la función `reset_index`:

```
rangos = rangos.reset_index()
rangos.head()
```

| | AGEB_cvgeo | level_1 | 0 |
|---|---|---|---|
| 0 | 0900200010010 | P_0A2 | 60.0 |
| 1 | 0900200010010 | P_0A2_F | 32.0 |
| 2 | 0900200010010 | P_0A2_M | 28.0 |
| 3 | 0900200010010 | P_3YMAS | 3123.0 |
| 4 | 0900200010010 | P_3YMAS_F | 1663.0 |

Ahora tenemos un DataFrame en el que el valor de la columna `AGEB_cvgeo` viene repetido para cada observación. Ya sólo necesitamos renombrar las columnas restantes para que nos indiquen más claramente su contenido:

```
rangos = rangos.rename(columns = {'level_1':'Grupo', 0:'Población'})
rangos.head()
```

| | AGEB_cvgeo | Grupo | Población |
|---|---|---|---|
| 0 | 0900200010010 | P_0A2 | 60.0 |
| 1 | 0900200010010 | P_0A2_F | 32.0 |
| 2 | 0900200010010 | P_0A2_M | 28.0 |
| 3 | 0900200010010 | P_3YMAS | 3123.0 |
| 4 | 0900200010010 | P_3YMAS_F | 1663.0 |

!Ahora tenemos nuestra tabla acomodada a los principios *tidy*!

## 1.7 Agrupamiento, Transformación y Agregación

Una ventaja de tener los datos estructurados de acuerdo a los principios *tidy* es la facilidad con la que podemos realizar procesos de transformación más sofisticados como agrupaciones y sumarios. Las agrupaciones consisten en *agrupar* observaciones en una tabla de acuerdo a sus valores (o expresiones) en una columna, a los datos agrupados se le pueden aplicar operaciones de agregación más o menos arbitrarias.

Digamos, por ejemplo, que queremos obtener los totales de población para cada grupo etario a través de todas las AGEBs. Para hacer esto tenemos que *agrupar* las observaciones por cada `Grupo` y después obtener el valor agregado por la suma. Vamos por partes.

```
grupos = rangos.groupby('Grupo')
grupos
```

```
<pandas.core.groupby.generic.DataFrameGroupBy object at 0x7f70945509d0>
```

La función `groupby` nos permite agrupar los datos de acuerdo a una (o más) columnas. El resultado, como pueden ver, no es un DataFrame sino un objeto de la clase especial `pandas.core.groupby.generic.DataFrameGroupBy`. Esta clase sirve para representar DataFrames *agregados*, estos objetos nos permiten obtener de forma fácil los valores que corresponden a diferentes funciones de *agregación*. Por ejemplo, para obtener el total de posblación por cada grupo, podemos agregar nuestro objeto con la función `sum`:

```
grupos.sum(numeric_only=True)
```

| Grupo | Población |
|---|---|
| P_0A2 | 264424.0 |
| P_0A2_F | 130297.0 |
| P_0A2_M | 134053.0 |
| P_12A14 | 364225.0 |
| P_12A14_F | 179955.0 |
| P_12A14_M | 184240.0 |
| P_12YMAS | 7864313.0 |
| P_12YMAS_F | 4141887.0 |
| P_12YMAS_M | 3722424.0 |
| P_15A17 | 377178.0 |
| P_15A17_F | 185144.0 |
| P_15A17_M | 191984.0 |
| P_15A49_F | 2490275.0 |
| P_15YMAS | 7500071.0 |
| P_15YMAS_F | 3961914.0 |
| P_15YMAS_M | 3538155.0 |
| P_18A24 | 975897.0 |
| P_18A24_F | 483893.0 |
| P_18A24_M | 491985.0 |
| P_18YMAS | 7122878.0 |
| P_18YMAS_F | 3776738.0 |
| P_18YMAS_M | 3346138.0 |
| P_3A5 | 321650.0 |
| P_3A5_F | 158674.0 |
| P_3A5_M | 162933.0 |
| P_3YMAS | 8871506.0 |
| P_3YMAS_F | 4637724.0 |
| P_3YMAS_M | 4233780.0 |
| P_5YMAS | 8660874.0 |
| P_5YMAS_F | 4533469.0 |
| P_5YMAS_M | 4127403.0 |
| P_60YMAS | 1487004.0 |
| P_60YMAS_F | 850901.0 |
| P_60YMAS_M | 636074.0 |
| P_6A11 | 685511.0 |
| P_6A11_F | 337113.0 |
| P_6A11_M | 348375.0 |
| P_8A14 | 829786.0 |
| P_8A14_F | 408494.0 |

| Grupo | Población |
|---|---|
| P_8A14_M | 421280.0 |

Como ve, al usar un *agregador* sobre el objeto agrupado obtenemos un DataFrame con los valores que corresponden a la agregación que utilizamos.

> **Note**
>
> El parámetro `numeric_only=True` le dice al agregador que sólo calcule el resultado para las columnas de tipo numérico.

En este caso la función que usamos para agregar los datos es la suma, sin embargo es posible utilizar cualquier función que opere sobre grupos de observaciones, por ejemplo, el promedio:

```
grupos.mean(numeric_only=True)
```

| Grupo | Población |
|---|---|
| P_0A2 | 109.901912 |
| P_0A2_F | 54.471990 |
| P_0A2_M | 56.089121 |
| P_12A14 | 151.130705 |
| P_12A14_F | 74.701121 |
| P_12A14_M | 76.702748 |
| P_12YMAS | 3245.692530 |
| P_12YMAS_F | 1710.110239 |
| P_12YMAS_M | 1536.287247 |
| P_15A17 | 156.310816 |
| P_15A17_F | 77.014975 |
| P_15A17_M | 79.993333 |
| P_15A49_F | 1028.614209 |
| P_15YMAS | 3095.365662 |
| P_15YMAS_F | 1635.802642 |
| P_15YMAS_M | 1460.237309 |
| P_18A24 | 403.596774 |
| P_18A24_F | 200.038446 |
| P_18A24_M | 204.143154 |
| P_18YMAS | 2939.693768 |
| P_18YMAS_F | 1559.346821 |

| Grupo | Población |
|---|---|
| P_18YMAS_M | 1380.989682 |
| P_3A5 | 133.298798 |
| P_3A5_F | 65.949293 |
| P_3A5_M | 67.775790 |
| P_3YMAS | 3661.372678 |
| P_3YMAS_F | 1914.832370 |
| P_3YMAS_M | 1747.329757 |
| P_5YMAS | 3574.442427 |
| P_5YMAS_F | 1871.787366 |
| P_5YMAS_M | 1703.426744 |
| P_60YMAS | 615.481788 |
| P_60YMAS_F | 353.511010 |
| P_60YMAS_M | 264.040681 |
| P_6A11 | 284.326421 |
| P_6A11_F | 140.055256 |
| P_6A11_M | 144.734109 |
| P_8A14 | 343.739022 |
| P_8A14_F | 169.218724 |
| P_8A14_M | 174.587650 |

Las funciones que usamos para agregar (`sum` y `mean`) son funciones de `numpy`y podemos utiliizar cualquier función de agregación. También es posible calcular diferentes agregaciones al mismo tiempo:

```
grupos.aggregate([np.sum, np.mean, np.std])
```

```
/tmp/ipykernel_5237/732611272.py:1: FutureWarning: ['AGEB_cvgeo'] did not aggregate successfu
  grupos.aggregate([np.sum, np.mean, np.std])
```

| Grupo | Población | | |
|---|---|---|---|
| | sum | mean | std |
| P_0A2 | 264424.0 | 109.901912 | 85.636899 |
| P_0A2_F | 130297.0 | 54.471990 | 42.286817 |
| P_0A2_M | 134053.0 | 56.089121 | 43.908616 |
| P_12A14 | 364225.0 | 151.130705 | 111.565262 |
| P_12A14_F | 179955.0 | 74.701121 | 55.572013 |

| Grupo | Población sum | mean | std |
|---|---|---|---|
| P_12A14_M | 184240.0 | 76.702748 | 56.746606 |
| P_12YMAS | 7864313.0 | 3245.692530 | 2056.644056 |
| P_12YMAS_F | 4141887.0 | 1710.110239 | 1073.566831 |
| P_12YMAS_M | 3722424.0 | 1536.287247 | 1001.153466 |
| P_15A17 | 377178.0 | 156.310816 | 113.532155 |
| P_15A17_F | 185144.0 | 77.014975 | 56.107357 |
| P_15A17_M | 191984.0 | 79.993333 | 57.996607 |
| P_15A49_F | 2490275.0 | 1028.614209 | 692.206450 |
| P_15YMAS | 7500071.0 | 3095.365662 | 1955.668987 |
| P_15YMAS_F | 3961914.0 | 1635.802642 | 1023.764553 |
| P_15YMAS_M | 3538155.0 | 1460.237309 | 950.879515 |
| P_18A24 | 975897.0 | 403.596774 | 279.378732 |
| P_18A24_F | 483893.0 | 200.038446 | 138.590941 |
| P_18A24_M | 491985.0 | 204.143154 | 143.125222 |
| P_18YMAS | 7122878.0 | 2939.693768 | 1853.201763 |
| P_18YMAS_F | 3776738.0 | 1559.346821 | 973.233847 |
| P_18YMAS_M | 3346138.0 | 1380.989682 | 899.958704 |
| P_3A5 | 321650.0 | 133.298798 | 101.904268 |
| P_3A5_F | 158674.0 | 65.949293 | 50.305709 |
| P_3A5_M | 162933.0 | 67.775790 | 52.251282 |
| P_3YMAS | 8871506.0 | 3661.372678 | 2347.050678 |
| P_3YMAS_F | 4637724.0 | 1914.832370 | 1215.700184 |
| P_3YMAS_M | 4233780.0 | 1747.329757 | 1147.281855 |
| P_5YMAS | 8660874.0 | 3574.442427 | 2284.544513 |
| P_5YMAS_F | 4533469.0 | 1871.787366 | 1185.089392 |
| P_5YMAS_M | 4127403.0 | 1703.426744 | 1115.802146 |
| P_60YMAS | 1487004.0 | 615.481788 | 358.110680 |
| P_60YMAS_F | 850901.0 | 353.511010 | 206.712937 |
| P_60YMAS_M | 636074.0 | 264.040681 | 152.406790 |
| P_6A11 | 685511.0 | 284.326421 | 213.690386 |
| P_6A11_F | 337113.0 | 140.055256 | 105.214351 |
| P_6A11_M | 348375.0 | 144.734109 | 109.164209 |
| P_8A14 | 829786.0 | 343.739022 | 255.780534 |
| P_8A14_F | 408494.0 | 169.218724 | 126.379228 |
| P_8A14_M | 421280.0 | 174.587650 | 130.222008 |

## 1.8 Para Practicar

La organización *Wikileaks* posee una Base de Datos pública en la cual se contiene, entre otras cosas, el número de casualidades existentes durante los primeros años de la *Guerra de Afganistán*, la cual puede ser consultada a través de la siguiente liga:

https://docs.google.com/spreadsheets/d/1EAx8_ksSCmoWW_SlhFyq2QrRn0FNNhcg1TtDFJzZRgc/ed

A partir de los datos, realiza los siguientes ejercidios: * Descarga la tabla como un archivo de tipo `.csv` (Archivo –> Descargar como –> .csv, hoja actual). * Importa los datos a un DataFrame de Pandas. * Explora los datos generando estadísticas descriptivas y algunas gráficas. * Examina qué tanto se ajusta a los principios del *Tidy Data* y ajústalo según creas conveniente * Obten una cuenta total de las bajas por mes y genera una gráfica con dicho conteo.

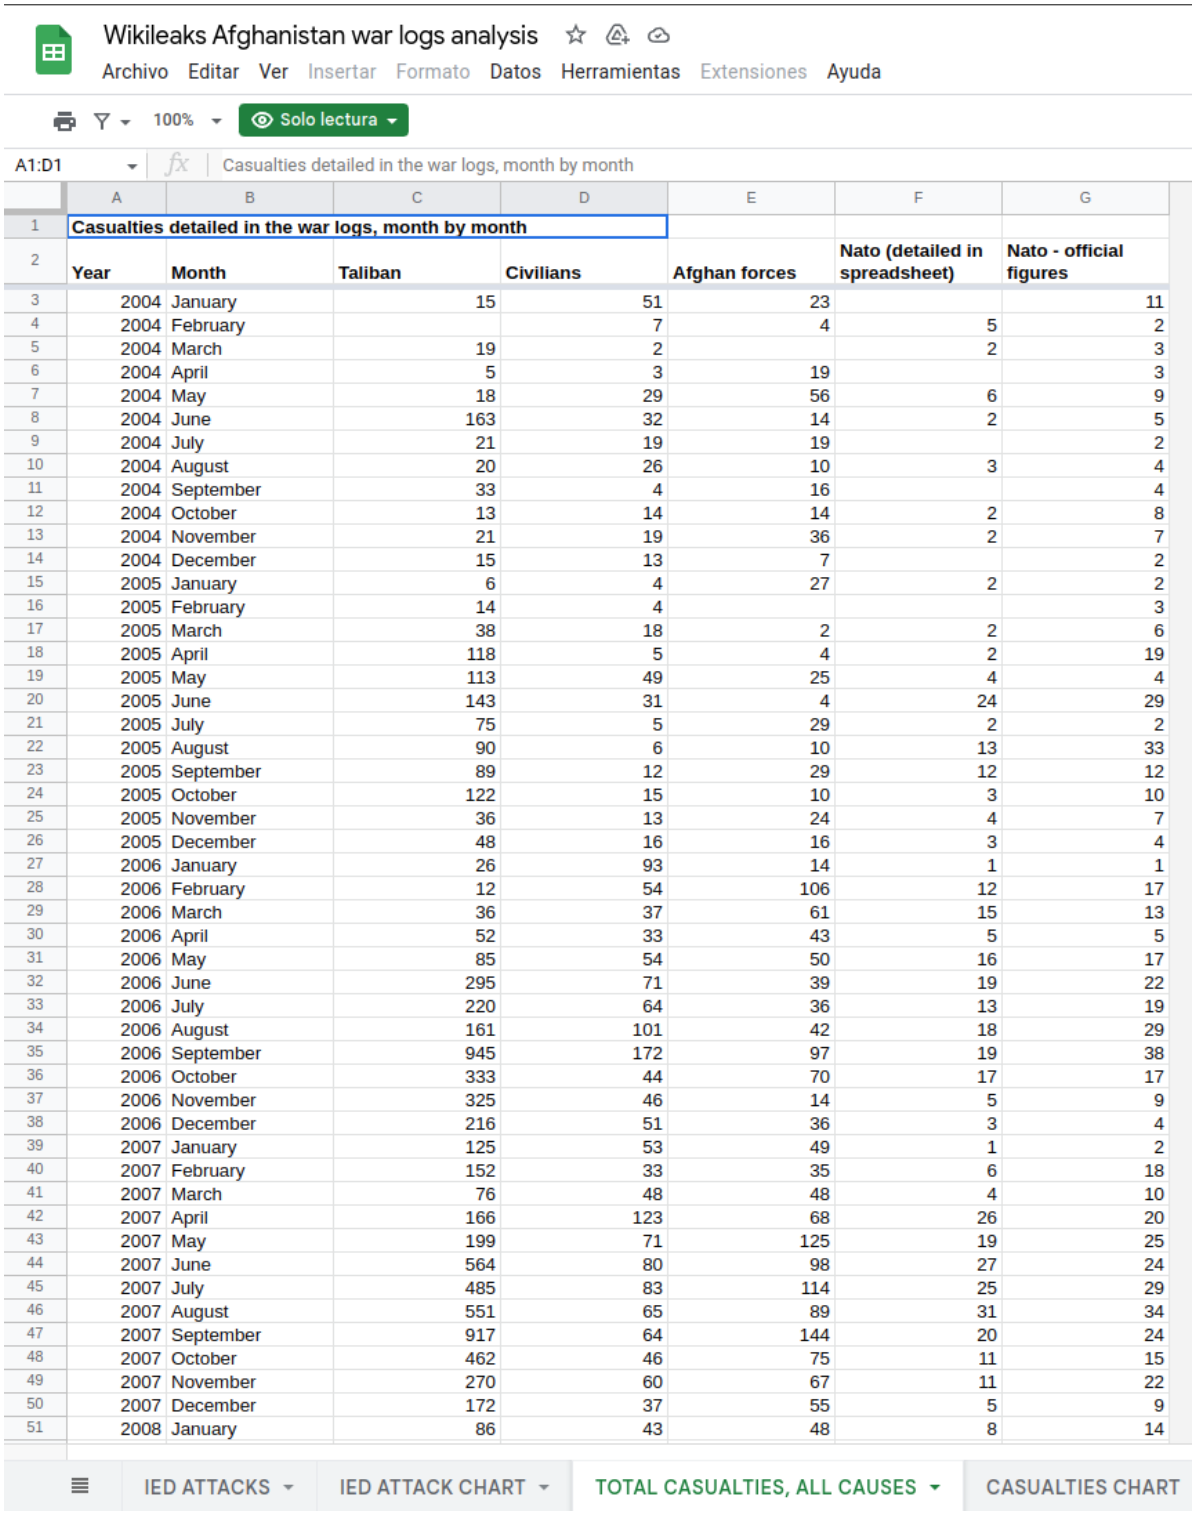

Wikileaks Afghanistan war logs analysis

Archivo Editar Ver Insertar Formato Datos Herramientas Extensiones Ayuda

100% Solo lectura

A1:D1 | Casualties detailed in the war logs, month by month

| | A | B | C | D | E | F | G |
|---|---|---|---|---|---|---|---|
| 1 | **Casualties detailed in the war logs, month by month** | | | | | | |
| 2 | **Year** | **Month** | **Taliban** | **Civilians** | **Afghan forces** | **Nato (detailed in spreadsheet)** | **Nato - official figures** |
| 3 | 2004 | January | 15 | 51 | 23 | | 11 |
| 4 | 2004 | February | | 7 | 4 | 5 | 2 |
| 5 | 2004 | March | 19 | 2 | | 2 | 3 |
| 6 | 2004 | April | 5 | 3 | 19 | | 3 |
| 7 | 2004 | May | 18 | 29 | 56 | 6 | 9 |
| 8 | 2004 | June | 163 | 32 | 14 | 2 | 5 |
| 9 | 2004 | July | 21 | 19 | 19 | | 2 |
| 10 | 2004 | August | 20 | 26 | 10 | 3 | 4 |
| 11 | 2004 | September | 33 | 4 | 16 | | 4 |
| 12 | 2004 | October | 13 | 14 | 14 | 2 | 8 |
| 13 | 2004 | November | 21 | 19 | 36 | 2 | 7 |
| 14 | 2004 | December | 15 | 13 | 7 | | 2 |
| 15 | 2005 | January | 6 | 4 | 27 | 2 | 2 |
| 16 | 2005 | February | 14 | 4 | | | 3 |
| 17 | 2005 | March | 38 | 18 | 2 | 2 | 6 |
| 18 | 2005 | April | 118 | 5 | 4 | 2 | 19 |
| 19 | 2005 | May | 113 | 49 | 25 | 4 | 4 |
| 20 | 2005 | June | 143 | 31 | 4 | 24 | 29 |
| 21 | 2005 | July | 75 | 5 | 29 | 2 | 2 |
| 22 | 2005 | August | 90 | 6 | 10 | 13 | 33 |
| 23 | 2005 | September | 89 | 12 | 29 | 12 | 12 |
| 24 | 2005 | October | 122 | 15 | 10 | 3 | 10 |
| 25 | 2005 | November | 36 | 13 | 24 | 4 | 7 |
| 26 | 2005 | December | 48 | 16 | 16 | 3 | 4 |
| 27 | 2006 | January | 26 | 93 | 14 | 1 | 1 |
| 28 | 2006 | February | 12 | 54 | 106 | 12 | 17 |
| 29 | 2006 | March | 36 | 37 | 61 | 15 | 13 |
| 30 | 2006 | April | 52 | 33 | 43 | 5 | 5 |
| 31 | 2006 | May | 85 | 54 | 50 | 16 | 17 |
| 32 | 2006 | June | 295 | 71 | 39 | 19 | 22 |
| 33 | 2006 | July | 220 | 64 | 36 | 13 | 19 |
| 34 | 2006 | August | 161 | 101 | 42 | 18 | 29 |
| 35 | 2006 | September | 945 | 172 | 97 | 19 | 38 |
| 36 | 2006 | October | 333 | 44 | 70 | 17 | 17 |
| 37 | 2006 | November | 325 | 46 | 14 | 5 | 9 |
| 38 | 2006 | December | 216 | 51 | 36 | 3 | 4 |
| 39 | 2007 | January | 125 | 53 | 49 | 1 | 2 |
| 40 | 2007 | February | 152 | 33 | 35 | 6 | 18 |
| 41 | 2007 | March | 76 | 48 | 48 | 4 | 10 |
| 42 | 2007 | April | 166 | 123 | 68 | 26 | 20 |
| 43 | 2007 | May | 199 | 71 | 125 | 19 | 25 |
| 44 | 2007 | June | 564 | 80 | 98 | 27 | 24 |
| 45 | 2007 | July | 485 | 83 | 114 | 25 | 29 |
| 46 | 2007 | August | 551 | 65 | 89 | 31 | 34 |
| 47 | 2007 | September | 917 | 64 | 144 | 20 | 24 |
| 48 | 2007 | October | 462 | 46 | 75 | 11 | 15 |
| 49 | 2007 | November | 270 | 60 | 67 | 11 | 22 |
| 50 | 2007 | December | 172 | 37 | 55 | 5 | 9 |
| 51 | 2008 | January | 86 | 43 | 48 | 8 | 14 |

IED ATTACKS | IED ATTACK CHART | TOTAL CASUALTIES, ALL CAUSES | CASUALTIES CHART

Figure 1.1: Wikileaks

# 2 Ejemplo: datos COVID-19

Las bases de datos provenientes de situaciones reales son problemáticas, no están limpias, pueden tener datos faltantes, codoficar los datos de formas extrañas, combinar tipos de datos, etcétera.

Es bien sabido que dentro de la Ciencia de Datos, se tenga la componente espacial o no, el trabajo no sólo se enfoca a generar modelos sofisticados o al análisis mismo, sino también a tareas mucho más básicas y menos exóticas como obtener los datos, procesarlos y modificarlos de forma que puedan ser examinados y explorados para entender sus propiedades básicas.

Dado lo extenuantes y relevantes que son estas tareas, es sorprendente encontrar que existen muy pocas publicaciones referentes a los patrones, técnicas y buenas prácticas existentes para una eficiente limpieza, manipulación y transformación de los datos.

En este taller nos vamos a enfocar en utilizar una base de datos del mundo real para aprender, utilizando Python, tćnicas para manipularlas, transformarlas y lim,piarlas de forma que podamos hacer análisis.

La base de datos que vamos a utilizar son los datos abiertos que publica diarimente la Dirección General de Epidemiología de la Secretaría de Salud. Esta es una base muy grande y compleja que incluye el seguimiento de todos los casos confirmados de COVID en México.

Antes de empezar a analizar la base de datos, vamos a importar las librerías que utilizaremos en el taller.

```
import os # hablar con el sistema operativo
import glob # listar directorios y ese tipo de operaciones
import itertools # herramientas para iterar objetos
from pathlib import Path # manipular rutas a directorios
import zipfile # comprimir y descomprimir archivos
import numpy as np # operaciones vectorizadas
import pandas as pd # DataFrames
from datetime import timedelta, date, datetime # Manejar fechas
import openpyxl # leer/escribir archivos de exel
import requests # Hablar con direcciones web
import logging
```

## 2.1 Descargar datos

El primer paso es, evidentemente, descargar los datos. Es claro que podríamos ir a la página de la Dirección General de Epidemiología (DGE) y descargarlos, sin embargo, lo vamos a hacer por el camino difícil de bajarlos usando Python.

Para eso, vamos a definir una función que tome como argumento la fecha para la que queremos descargar los datos y el *path* en donde los vamos a guardar. La función es relativamente simple, sólo hace un *request* al archivo histórico de la DGE y guarda los datos en la ruta configurada.

Para trabajar vamos siempre a descargar tres archivos:

- Los datos COVID-19
- El catálogo de campos
- El archivo de descripción

El primer archivo contiene la serie de tiempo de seguimiento de casos hasta la fecha configurada, los dos archivos restantes sirven para entender la información contenida en los datos.

Entonces, primero definimos la función

```
def bajar_datos_salud(directorio_datos='data/', fecha='10-01-2022'):
    '''
        Descarga el archivo de datos y los diccionarios para la fecha solicitada.
    '''
    fecha = datetime.strptime(fecha, "%d-%m-%Y")
    url_salud_historicos = 'http://datosabiertos.salud.gob.mx/gobmx/salud/datos_abiertos/h
    archivo_nombre = f'{fecha.strftime("%y%m%d")}COVID19MEXICO.csv.zip'
    archivo_ruta = os.path.join(directorio_datos, archivo_nombre)
    url_diccionario = 'http://datosabiertos.salud.gob.mx/gobmx/salud/datos_abiertos/diccio
    diccionario_ruta = os.path.join(directorio_datos, 'diccionario.zip')
    if os.path.exists(archivo_ruta):
        logging.debug(f'Ya existe {archivo_nombre}')
    else:
        print(f'Bajando datos {fecha.strftime("%d.%m.%Y")}')
        url_dia = "{}/{}/datos_abiertos_covid19_{}.zip".format(fecha.strftime('%Y'),
                                                               fecha.strftime('%m'),
                                                               fecha.strftime('%d.%m.%Y')
        url = url_salud_historicos + url_dia
        r = requests.get(url, allow_redirects=True)
        open(archivo_ruta, 'wb').write(r.content)
        r = requests.get(url_diccionario, allow_redirects=True)
        open(diccionario_ruta, 'wb').write(r.content)
        with zipfile.ZipFile(diccionario_ruta, 'r') as zip_ref:
```

```
            zip_ref.extractall(directorio_datos)
```

Con la función que acabamos de definir, podemos bajar los datos hasta la última fecha disponible

```
ayer = datetime.now() - timedelta(1)
bajar_datos_salud(fecha=ayer.strftime('%d-%m-%Y'))
```

## 2.2 Exploración del contenido

Antes de empezar a manipular los datos, lo primero que tenemos que hacer es explorarlos brevemente y entender cómo están organizados. Leamos los datos en un DataFrame.

Fíjense en la ruta en donde la función de arriba descarga los datos, con la barra exploradora del lado izquierdo pueden navegar hasta esa ruta y copiar el *path*.

Para leer los datos vamos a utilizar la función read_csv(), esta función (como pueden ver) acepta que el csv venga comprimido en un zip.

```
df = pd.read_csv('data/220110COVID19MEXICO.csv.zip', dtype=object, encoding='latin-1')
df.head()
```

| | FECHA_ACTUALIZACION | ID_REGISTRO | ORIGEN | SECTOR | ENTIDAD_UM | SEXO | ENT |
|---|---|---|---|---|---|---|---|
| 0 | 2022-01-10 | zz7202 | 1 | 12 | 16 | 2 | 16 |
| 1 | 2022-01-10 | z58ed3 | 2 | 12 | 18 | 1 | 18 |
| 2 | 2022-01-10 | z3be8c | 2 | 12 | 07 | 1 | 07 |
| 3 | 2022-01-10 | z526b3 | 2 | 12 | 09 | 1 | 09 |
| 4 | 2022-01-10 | z3d1e2 | 2 | 12 | 09 | 1 | 09 |

Cada renglón en la base de datos corresponde a un caso en seguimiento, el resultado de cada caso se puede actualizar en sucesivas publicaciones de la base de datos. Las columnas describen un conjunto de variables asociadas al seguimiento de cada uno de los casos. Las dos primeras columnas corresponden a la fecha en la que se actualizó el caso y a un id único para cada caso respectivamente, en este taller no vamos a usar esas dos columnas.

Luego vienen un conjunto de columnas que describen la unidad médica de reporte y, después, las columnas que nos interesan más, que son las que describen al paciente.

Para entender un poco mejor los datos, conviene leer el archívo de catálogo. Pueden descargarlo en el explorador de archivos del lado izquierdo, pero aquí vamos a abrirlo y explorarlo un poco

con Pandas. Como el catálogo es un archivo de excel con varias hojas, lo vamos a leer usando openpyxl que nos va a devolver un diccionario de DataFrames que relacionan el nombre de la hoja con los datos que contiene.

```
catalogos = 'data/201128 Catalogos.xlsx'
nombres_catalogos = ['Catálogo de ENTIDADES', # Acá están los nombres de las hojas del exc
                     'Catálogo MUNICIPIOS',
                     'Catálogo SI_NO',
                     'Catálogo TIPO_PACIENTE',
                     'Catálogo CLASIFICACION_FINAL',
                     'Catálogo RESULTADO_LAB'
                    ]
# read_excel nos regresa un diccionario que relaciona el nombre de cada hoja con
# el contenido de la hoja como DataFrame
dict_catalogos = pd.read_excel(catalogos,
                               nombres_catalogos,
                               dtype=str,
                               engine='openpyxl')
clasificacion_final = dict_catalogos['Catálogo CLASIFICACION_FINAL']
# Aquí le damos nombre a las columnas porque en el excel se saltan dos líneas
clasificacion_final.columns = ["CLAVE", "CLASIFICACIÓN", "DESCRIPCIÓN"]
clasificacion_final
```

| | CLAVE | CLASIFICACIÓN | DESCRIPCIÓN |
|---|---|---|---|
| 0 | NaN | NaN | NaN |
| 1 | CLAVE | CLASIFICACIÓN | DESCRIPCIÓN |
| 2 | 1 | CASO DE COVID-19 CONFIRMADO POR ASOCIACIÓN CLÍ... | Confirmado por asociación |
| 3 | 2 | CASO DE COVID-19 CONFIRMADO POR COMITÉ DE DIC... | Confirmado por dictaminac |
| 4 | 3 | CASO DE SARS-COV-2 CONFIRMADO | Confirmado aplica cuando:\ |
| 5 | 4 | INVÁLIDO POR LABORATORIO | Inválido aplica cuando el ca |
| 6 | 5 | NO REALIZADO POR LABORATORIO | No realizado aplica cuando |
| 7 | 6 | CASO SOSPECHOSO | Sospechoso aplica cuando: |
| 8 | 7 | NEGATIVO A SARS-COV-2 | Negativo aplica cuando el c |

Lo que estamos viendo aquí es el catálogo de datos de la columna `CLASIFICACION_FINAL`. Este catálogo relaciona el valor de la `CLAVE` con su significado. En particular, la columna `CLASIFICACION_FINAL` es la que nos permite identificar los casos positivos como veremos más adelante.

El resto de los catálogos funciona de la misma forma, en este momento sólo vamos a utilizar la clasificación de los pacientes, pero más adelante podemos utilzar algunas de las columnas restantes.

## 2.3 Aplanado de datos

Como acabamos de ver, de alguna forma la información viene *distribuida* en tres archivos, uno con los datos, otro con las categorías que usa y un tercero con sus descripciones. Para utilizar los datos más fácilmente, sobre todo para poder hablarle a las cosas *por su nombre* en lugar de referirnos a sus valores codificados, vamos a realizar un conjunto de operaciones para *aplanar* los datos.

En el bajo mundo del análisis de datos, *aplanar* una base de datos es la operación de substituir los valores codificados a partir de un diccionario. En este caso, los datos que leímos traen valores codificados, entonces la primera misión es substituir esos valores por sus equivalentes en el diccionario.

Como la base de datos es muy grande, vamos a trabajar sólo con un estado de la república, en este caso la Ciudad de México (pero ustedes podrían elegir otro cualquiera).

Para seleccionar un estado, tenemos que *elegir* las filas del DataFrame que contengan el valor que queremos en la columna *ENTIDAD*, para eso vamos a aprender a usar nuestro primer operador de Pandas, el operador loc que nos permite seleccionar filas a partir de los valores de una o más columnas.

```
# el copy() nos asegura tener una copia de los datos en lugar de una referencia,
# con eso podemos liberar la memoria más fácil
df = df.loc[df['ENTIDAD_RES'] == '09'].copy()
df.head()
```

| | FECHA_ACTUALIZACION | ID_REGISTRO | ORIGEN | SECTOR | ENTIDAD_UM | SEXO |
|---|---|---|---|---|---|---|
| 3 | 2022-01-10 | z526b3 | 2 | 12 | 09 | 1 |
| 4 | 2022-01-10 | z3d1e2 | 2 | 12 | 09 | 1 |
| 11 | 2022-01-10 | z29dac | 2 | 12 | 09 | 1 |
| 15 | 2022-01-10 | z45dcb | 2 | 12 | 09 | 2 |
| 22 | 2022-01-10 | z23c2e | 2 | 12 | 09 | 1 |
| ... | ... | ... | ... | ... | ... | ... |
| 12731369 | 2022-01-10 | m00073e | 2 | 12 | 15 | 2 |
| 12731784 | 2022-01-10 | m030623 | 2 | 12 | 15 | 2 |
| 12731821 | 2022-01-10 | m049633 | 2 | 12 | 15 | 1 |
| 12732221 | 2022-01-10 | m160d02 | 2 | 12 | 15 | 2 |
| 12732863 | 2022-01-10 | m0da9ec | 2 | 12 | 15 | 1 |

Fíjense que lo que hicimos fue reescribir en la variable `df` el resultado de nuestra selección, de forma que `df` ahora sólo contiene resultados para la CDMX.

Ahora ya con los datos filtrados y, por lo tanto, con un tamaño más manejable, vamos a empezar a trabajarlos. Lo primero que vamos a hacer es cambiar los valores de la columna *MUNICIPIO_RES* por la concatenación de las claves de estado y municipio, esto porque nos hará más adelante más fácil el trabajo de unir los datos con las geometrías de los municipios y porque además así tendremos un identificador único para estos (claro que esto sólo tiene sentido al trabajar con varios estados al mismo tiempo).

```
df['MUNICIPIO_RES'] = df['ENTIDAD_RES'] + df['MUNICIPIO_RES']
df.head()
```

| | FECHA_ACTUALIZACION | ID_REGISTRO | ORIGEN | SECTOR | ENTIDAD_UM | SEXO | EN |
|---|---|---|---|---|---|---|---|
| 3 | 2022-01-10 | z526b3 | 2 | 12 | 09 | 1 | 09 |
| 4 | 2022-01-10 | z3d1e2 | 2 | 12 | 09 | 1 | 09 |
| 11 | 2022-01-10 | z29dac | 2 | 12 | 09 | 1 | 09 |
| 15 | 2022-01-10 | z45dcb | 2 | 12 | 09 | 2 | 09 |
| 22 | 2022-01-10 | z23c2e | 2 | 12 | 09 | 1 | 09 |

Ahora vamos a corregir el nombre de una columna en la base de datos para que coincida con el nombre en el diccionario y después podamos buscar automáticamente. Pra corregir el nombre de la columna vamos a utilizar la función rename de Pandas. Esta función nos sirve para renombrar filas (el índice del DataFrame, que vamos a ver más adelante) o columnas dependiendo de qué eje seleccionemos. El eje 0 son las filas y el 1 las columnas.

```
# Como estamos usando explícitamente el parámetro columns,
# no necesitamos especificar el eje
df = df.rename(columns={'OTRA_COM': 'OTRAS_COM'})
df.columns
```

```
Index(['FECHA_ACTUALIZACION', 'ID_REGISTRO', 'ORIGEN', 'SECTOR', 'ENTIDAD_UM',
       'SEXO', 'ENTIDAD_NAC', 'ENTIDAD_RES', 'MUNICIPIO_RES', 'TIPO_PACIENTE',
       'FECHA_INGRESO', 'FECHA_SINTOMAS', 'FECHA_DEF', 'INTUBADO', 'NEUMONIA',
       'EDAD', 'NACIONALIDAD', 'EMBARAZO', 'HABLA_LENGUA_INDIG', 'INDIGENA',
       'DIABETES', 'EPOC', 'ASMA', 'INMUSUPR', 'HIPERTENSION', 'OTRAS_COM',
       'CARDIOVASCULAR', 'OBESIDAD', 'RENAL_CRONICA', 'TABAQUISMO',
       'OTRO_CASO', 'TOMA_MUESTRA_LAB', 'RESULTADO_LAB',
       'TOMA_MUESTRA_ANTIGENO', 'RESULTADO_ANTIGENO', 'CLASIFICACION_FINAL',
       'MIGRANTE', 'PAIS_NACIONALIDAD', 'PAIS_ORIGEN', 'UCI'],
      dtype='object')
```

Fíjense cómo otra vez reescribimos la variable `df`. La mayor parte de las operaciones en Pandas regresan un DataFrame con el resultado de la operación y no modifican el DataFrame original, entonces para *guardar* los resultados, necesitamos reescribir la variable (o guardarla con otro nombre)

Ahora sí podemos empezar a *aplanar* los datos. Vamos a empezar por resolver las claves de resultado de las pruebas COVID. En los datos originales estos vienen codificados en la columna **RESULTADO_LAB**, pero en el diccionario ese velor se llama **RESULTADO**, entonces otra vez vamos a empezar por renombrar una columna.

```
df = df.rename(columns={'RESULTADO_LAB': 'RESULTADO'})
```

Para sustituir los valores en nuestros datos originales vamos a usar la función map que toma una serie (una serie es una columna de un dataframe) y *mapea* sus valores de acuerdo a una correspondencia que podemos pasar como un diccionario. Veamos poco a poco cómo hacer lo que queremos.

Lo primero que necesitamos es un diccionario que relacione los valores en nuestros datos con los nombres en el diccionario. Recordemos cómo se ve el diccionario:

```
clasificacion_final
```

| | CLAVE | CLASIFICACIÓN | DESCRIPCIÓN |
|---|---|---|---|
| 0 | NaN | NaN | NaN |
| 1 | CLAVE | CLASIFICACIÓN | DESCRIPCIÓN |
| 2 | 1 | CASO DE COVID-19 CONFIRMADO POR ASOCIACIÓN CLÍ... | Confirmado por asociación |
| 3 | 2 | CASO DE COVID-19 CONFIRMADO POR COMITÉ DE DIC... | Confirmado por dictaminac |
| 4 | 3 | CASO DE SARS-COV-2 CONFIRMADO | Confirmado aplica cuando:' |
| 5 | 4 | INVÁLIDO POR LABORATORIO | Inválido aplica cuando el ca |
| 6 | 5 | NO REALIZADO POR LABORATORIO | No realizado aplica cuando |
| 7 | 6 | CASO SOSPECHOSO | Sospechoso aplica cuando: |
| 8 | 7 | NEGATIVO A SARS-COV-2 | Negativo aplica cuando el c |

Necesitamos un diccionario `{CLASIFICACION:CLAVE}` (ya sé que hay unos valores espurios, pero no nos importan porque simplemente esos no los va a encontrar en nuestra base de datos).

Para construir este diccionario, vamos a empezar por construir la *tupla* que mantiene la relación que buscamos, para eso vamos a utilizar la función zip que toma dos *iteradores* como entrada y regresa un *iterador* que tiene por elementos las tuplas hechas elemento a elemento entre los dos iteradores de inicio. Veamoslo con calma:

```
l1 = ['a', 'b', 'c']
l2 = [1, 2, 3]
l3 = list(zip(l1,l2))
l3
```

```
[('a', 1), ('b', 2), ('c', 3)]
```

Lo que nos regresa `zip` es un iterado con las tuplas formadas por los pares ordenados de los iteradores de entrada. En Python un iterador es cualquier cosa que se pueda *recorrer en orden*, a veces estos iteradores, como en el caso de `zip` no regresan todas las entradas sino, para ahorrar memoria, las generan conforme se recorren, por eso hay que hacer `list(zip)` para que se generen las entradas.

Ahora sí podemos entonces crear el diccionario con el que vamos a actualizar los datos:

```
clasificacion_final = dict(zip(clasificacion_final['CLAVE'], clasificacion_final['CLASIFIC
clasificacion_final
```

```
{nan: nan,
 'CLAVE': 'CLASIFICACIÓN',
 '1': 'CASO DE COVID-19 CONFIRMADO POR ASOCIACIÓN CLÍNICA EPIDEMIOLÓGICA',
 '2': 'CASO DE COVID-19 CONFIRMADO POR COMITÉ DE  DICTAMINACIÓN',
 '3': 'CASO DE SARS-COV-2  CONFIRMADO',
 '4': 'INVÁLIDO POR LABORATORIO',
 '5': 'NO REALIZADO POR LABORATORIO',
 '6': 'CASO SOSPECHOSO',
 '7': 'NEGATIVO A SARS-COV-2'}
```

Y entonces pasarlo como argumento a la función `map`. Hay un truco aquí, `map` toma como argumento una función que, para cada llave, regresa el valor correspondiente, entonces no es propiamente el diccionario lo que vamos a pasar, sino la función get del diccionario que hace justo lo que queremos. Esto nos revela una prpiedad curiosa de Python, los argumentos de una función pueden ser funciones.

```
df['CLASIFICACION_FINAL'] = df['CLASIFICACION_FINAL'].map(clasificacion_final.get)
df['CLASIFICACION_FINAL'].head()
```

```
3     CASO DE SARS-COV-2  CONFIRMADO
4     CASO DE SARS-COV-2  CONFIRMADO
11      NO REALIZADO POR LABORATORIO
15            NEGATIVO A SARS-COV-2
22                  CASO SOSPECHOSO
Name: CLASIFICACION_FINAL, dtype: object
```

Ahora vamos a hacer una sustitución un poco más compleja, tenemos que encontrar todos los campos de tipo "SI - NO" y resolverlos (sustituir por valores que podamos manejar más fácil). Los campos que tienen este tipo de datos vienen en el excel de descriptores:

```
descriptores = pd.read_excel('data/201128 Descriptores_.xlsx',
                             index_col='Nº',
                             engine='openpyxl')
descriptores
```

| Nº | NOMBRE DE VARIABLE | DESCRIPCIÓN DE VARIABLE | FORMATO O F |
|---|---|---|---|
| 1 | FECHA_ACTUALIZACION | La base de datos se alimenta diariamente, esta... | AAAA-MM-DD |
| 2 | ID_REGISTRO | Número identificador del caso | TEXTO |
| 3 | ORIGEN | La vigilancia centinela se realiza a través de... | CATÁLOGO: OI |
| 4 | SECTOR | Identifica el tipo de institución del Sistema ... | CATÁLOGO: SE |
| 5 | ENTIDAD_UM | Identifica la entidad donde se ubica la unidad... | CATALÓGO: EN |
| 6 | SEXO | Identifica al sexo del paciente. | CATÁLOGO: SE |
| 7 | ENTIDAD_NAC | Identifica la entidad de nacimiento del paciente. | CATALÓGO: EN |
| 8 | ENTIDAD_RES | Identifica la entidad de residencia del paciente. | CATALÓGO: EN |
| 9 | MUNICIPIO_RES | Identifica el municipio de residencia del paci... | CATALÓGO: MI |
| 10 | TIPO_PACIENTE | Identifica el tipo de atención que recibió el ... | CATÁLOGO: TI |
| 11 | FECHA_INGRESO | Identifica la fecha de ingreso del paciente a ... | AAAA-MM-DD |
| 12 | FECHA_SINTOMAS | Idenitifica la fecha en que inició la sintomat... | AAAA-MM-DD |
| 13 | FECHA_DEF | Identifica la fecha en que el paciente falleció. | AAAA-MM-DD |
| 14 | INTUBADO | Identifica si el paciente requirió de intubación. | CATÁLOGO: SI |
| 15 | NEUMONIA | Identifica si al paciente se le diagnosticó co... | CATÁLOGO: SI |
| 16 | EDAD | Identifica la edad del paciente. | NÚMERICA EN |
| 17 | NACIONALIDAD | Identifica si el paciente es mexicano o extran... | CATÁLOGO: NA |
| 18 | EMBARAZO | Identifica si la paciente está embarazada. | CATÁLOGO: SI |
| 19 | HABLA_LENGUA_INDIG | Identifica si el paciente habla lengua índigena. | CATÁLOGO: SI |
| 20 | INDIGENA | Identifica si el paciente se autoidentifica co... | CATÁLOGO: SI |
| 21 | DIABETES | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI |
| 22 | EPOC | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI |
| 23 | ASMA | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI |

| Nº | NOMBRE DE VARIABLE | DESCRIPCIÓN DE VARIABLE | FORMATO O F |
|---|---|---|---|
| 24 | INMUSUPR | Identifica si el paciente presenta inmunosupre... | CATÁLOGO: SI |
| 25 | HIPERTENSION | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI |
| 26 | OTRAS_COM | Identifica si el paciente tiene diagnóstico de... | CATÁLOGO: SI |
| 27 | CARDIOVASCULAR | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI |
| 28 | OBESIDAD | Identifica si el paciente tiene diagnóstico de... | CATÁLOGO: SI |
| 29 | RENAL_CRONICA | Identifica si el paciente tiene diagnóstico de... | CATÁLOGO: SI |
| 30 | TABAQUISMO | Identifica si el paciente tiene hábito de taba... | CATÁLOGO: SI |
| 31 | OTRO_CASO | Identifica si el paciente tuvo contacto con al... | CATÁLOGO: SI |
| 32 | TOMA_MUESTRA_LAB | Identifica si al paciente se le tomó muestra d... | CATÁLOGO: SI |
| 33 | RESULTADO_LAB | Identifica el resultado del análisis de la mue... | CATÁLOGO: RE |
| 34 | TOMA_MUESTRA_ANTIGENO | Identifica si al paciente se le tomó muestra d... | CATÁLOGO: SI |
| 35 | RESULTADO_ANTIGENO | Identifica el resultado del análisis de la mue... | CATÁLOGO: RE |
| 36 | CLASIFICACION_FINAL | Identifica si el paciente es un caso de COVID-... | CATÁLOGO: CI |
| 37 | MIGRANTE | Identifica si el paciente es una persona migra... | CATÁLOGO: SI |
| 38 | PAIS_NACIONALIDAD | Identifica la nacionalidad del paciente. | TEXTO, 99= SE |
| 39 | PAIS_ORIGEN | Identifica el país del que partió el paciente ... | TEXTO, 97= NO |
| 40 | UCI | Identifica si el paciente requirió ingresar a ... | CATÁLOGO: SI |

Fíjense en alguno de estos campos en los datos:

```
df['OBESIDAD'].unique()
```

```
array(['1', '2', '98'], dtype=object)
```

Tenemos tres valores diferentes que corresponden (vean el diccionario) a SI, NO y NO ESPECIFICADO. Para todos los análisis que vamos a hacer en general sólo nos van a interesar los casos que **sabemos** que son SI, entonces lo que más nos conviene es codificar todos estos como binarios, es decir, sólo SI o NO. Además, podemos mejor decirles 1,0 respectivamente y así vamos a poder hacer cuentas mucho más fácil

De estos descriptores nos interesan los que tienen `CATÁLOGO: SI_ NO` en el campo `FORMATO O FUENTE`. Para poder encontrar y sustituir de forma más sencilla y automática vamos a hacer un par de modificaciones a los datos:

- Reemplazar los espacios en los nombres de columnas por guiones bajos (para poder "hablarles" más fácil a las columnas)
- Quitar espacios al principio o al final de los valores de los campos (para asegurarnos de que siempre van a ser los mismos)

```
descriptores.columns = list(map(lambda col: col.replace(' ', '_'), descriptores.columns))
descriptores.head()
```

| Nº | NOMBRE_DE_VARIABLE | DESCRIPCIÓN_DE_VARIABLE | FORMATO_O_FUEN |
|---|---|---|---|
| 1 | FECHA_ACTUALIZACION | La base de datos se alimenta diariamente, esta... | AAAA-MM-DD |
| 2 | ID_REGISTRO | Número identificador del caso | TEXTO |
| 3 | ORIGEN | La vigilancia centinela se realiza a través de... | CATÁLOGO: ORIGE |
| 4 | SECTOR | Identifica el tipo de institución del Sistema ... | CATÁLOGO: SECTO |
| 5 | ENTIDAD_UM | Identifica la entidad donde se ubica la unidad... | CATALÓGO: ENTID |

Poco a poco:

- `descriptores.columns` nos regresa (o les da valor, cuando está del lado izquierdo de un `=`) los nombres de las columnas del DataFrame
- `map(lambda col: col.replace(' ', '_'), descriptores.columns)` la función `map` regresa una asosiación, como ya vimos. En este caso esta asosiación se hace a través de una *función anónima* lambda que toma como argumento el nombre de una columna y regresa el mismo nombre pero con los espacios sustituidos por guines bajos

Al final, lo que hacemos es sustituir los nombres de las columnas por una lista hecha por nosotros, para que esto funcione la lista que pasamos debe ser de igual tamaño que la lista original de columnas.

Ahora vamos a hacer lo mismo pero con los valores de los campos:

```
descriptores['FORMATO_O_FUENTE'] = descriptores.FORMATO_O_FUENTE.str.strip()
descriptores['FORMATO_O_FUENTE'].head()
```

```
Nº
1              AAAA-MM-DD
2                   TEXTO
3        CATÁLOGO: ORIGEN
4        CATÁLOGO: SECTOR
5     CATALÓGO: ENTIDADES
Name: FORMATO_O_FUENTE, dtype: object
```

Este fué más fácil. Fíjense cómo pedimos el campo del lado derecho: `descriptores.FORMATO_O_FUENTE`, esto es equivalente a `descriptores['FORMATO_O_FUENTE']` y los pueden usar indistintamente (claro, el primero sólo funciona si el nombre del campo no tiene espacios).

Perfecto, filtremos ahora los descriptores para quedarnos sólo con los que nos interesan, para eso vamos a usar la función query de Pandas, que nos permite filtrar un DataFrame de forma conveniente usando una expresión *booleana*:

```
datos_si_no = descriptores.query('FORMATO_O_FUENTE == "CATÁLOGO: SI_ NO"')
datos_si_no
```

| Nº | NOMBRE_DE_VARIABLE | DESCRIPCIÓN_DE_VARIABLE | FORMATO_O_F |
|---|---|---|---|
| 14 | INTUBADO | Identifica si el paciente requirió de intubación. | CATÁLOGO: SI_ |
| 15 | NEUMONIA | Identifica si al paciente se le diagnosticó co... | CATÁLOGO: SI_ |
| 18 | EMBARAZO | Identifica si la paciente está embarazada. | CATÁLOGO: SI_ |
| 19 | HABLA_LENGUA_INDIG | Identifica si el paciente habla lengua índigena. | CATÁLOGO: SI_ |
| 20 | INDIGENA | Identifica si el paciente se autoidentifica co... | CATÁLOGO: SI_ |
| 21 | DIABETES | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI_ |
| 22 | EPOC | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI_ |
| 23 | ASMA | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI_ |
| 24 | INMUSUPR | Identifica si el paciente presenta inmunosupre... | CATÁLOGO: SI_ |
| 25 | HIPERTENSION | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI_ |
| 26 | OTRAS_COM | Identifica si el paciente tiene diagnóstico de... | CATÁLOGO: SI_ |
| 27 | CARDIOVASCULAR | Identifica si el paciente tiene un diagnóstico... | CATÁLOGO: SI_ |
| 28 | OBESIDAD | Identifica si el paciente tiene diagnóstico de... | CATÁLOGO: SI_ |
| 29 | RENAL_CRONICA | Identifica si el paciente tiene diagnóstico de... | CATÁLOGO: SI_ |
| 30 | TABAQUISMO | Identifica si el paciente tiene hábito de taba... | CATÁLOGO: SI_ |
| 31 | OTRO_CASO | Identifica si el paciente tuvo contacto con al... | CATÁLOGO: SI_ |
| 32 | TOMA_MUESTRA_LAB | Identifica si al paciente se le tomó muestra d... | CATÁLOGO: SI_ |
| 34 | TOMA_MUESTRA_ANTIGENO | Identifica si al paciente se le tomó muestra d... | CATÁLOGO: SI_ |
| 37 | MIGRANTE | Identifica si el paciente es una persona migra... | CATÁLOGO: SI_ |
| 40 | UCI | Identifica si el paciente requirió ingresar a ... | CATÁLOGO: SI_ |

Por si acaso, quitémosle también los espacios al campo `FORMATO_O_FUENTE`

```
descriptores['FORMATO_O_FUENTE'] = descriptores.FORMATO_O_FUENTE.str.strip()
```

Ahora sí, vamos a sustituir los valores como queremos en los datos originales. Para eso, lo primero que tenemos que hacer es fijarnos en el catálogo de estos campos:

```
cat_si_no = dict_catalogos['Catálogo SI_NO']
cat_si_no
```

| | CLAVE | DESCRIPCIÓN |
|---|---|---|
| 0 | 1 | SI |
| 1 | 2 | NO |
| 2 | 97 | NO APLICA |
| 3 | 98 | SE IGNORA |
| 4 | 99 | NO ESPECIFICADO |

Justo estos valores los queremos cambiar por claves binarias (acuérdense, para distinguirlos fácilmente). Entonces lo que necesitamos ahora es:

- Una lista de los nombres de los campos en donde vamos a hacer la sustitución
- Un mapeo de los valores con los que vamos a sustituir
- Hacer la sustitución primero en el diccionario y a partir de eso en los datos originales

```
# lista de los nombres de los campos
campos_si_no = datos_si_no.NOMBRE_DE_VARIABLE
# sustituimos en el catálogo de acuerdo a lo que nos interesa
cat_si_no['DESCRIPCIÓN'] = list(map(lambda val: 1 if val == 'SI' else 0, cat_si_no['DESCRI
# sustituimos en los datos originales
df[campos_si_no] = df[datos_si_no.NOMBRE_DE_VARIABLE].replace(
                                                to_replace=cat_si_no['CLAVE'].values,
                                                value=cat_si_no['DESCRIPCIÓN'].values)

df[campos_si_no]
```

| | INTUBADO | NEUMONIA | EMBARAZO | HABLA_LENGUA_INDIG | INDIGENA | DIABE |
|---|---|---|---|---|---|---|
| 3 | 0 | 0 | 0 | 0 | 0 | 0 |
| 4 | 0 | 0 | 0 | 0 | 0 | 0 |
| 11 | 0 | 0 | 0 | 0 | 0 | 0 |
| 15 | 0 | 0 | 0 | 0 | 0 | 0 |
| 22 | 0 | 0 | 0 | 0 | 0 | 0 |
| ... | ... | ... | ... | ... | ... | ... |
| 12731369 | 0 | 0 | 0 | 0 | 0 | 0 |
| 12731784 | 0 | 0 | 0 | 0 | 0 | 0 |
| 12731821 | 0 | 0 | 0 | 0 | 0 | 0 |
| 12732221 | 0 | 0 | 0 | 0 | 0 | 0 |
| 12732863 | 0 | 0 | 0 | 0 | 0 | 0 |

Acá utilizamos para la última sustitución la función replace de Pandas que toma dos parámetros: la lista de valores a reemplazar y la lista de los valoresa de reemplazo. El reemplazo

sucede elemento a elemento, es decir, se sustituye el primer elemento de la lista `to_replace` por el primer elemento de la lista `value` y así sucesivamente.

Hay más campos que podemos *aplanar* en la base de datos, como ejercicio pueden explorar algunos de ellos y sustituir como le hemos hecho aquí. Regresaremos a esto más adelante en el taller, pero por lo pronto nos vamos a mover a otra etapa del pre-procesamiento: el manejo de las fechas

## 2.4 Manejo de fechas

En Python las fechas son un tipo especial de datos, nosotros estamos acostumbrados a verlas como cadenas de caractéres: 20 de febrero de 2010, por ejemplo. Python puede hacer muchas cosas con las fechas, pero para eso tienen que estar codificados de la forma correcta.

En general el módulo `datetime` de Python provee las utilerías necesarias para manejar/transformar objetos del tipo fecha. Una de las cosas más útiles es transformar strings en objetos `datetime`:

```
datetime_object = datetime.strptime('Jun 1 2005  1:33PM', '%b %d %Y %I:%M%p')
datetime_object
```

```
datetime.datetime(2005, 6, 1, 13, 33)
```

Acá usamos un formato de fecha, `'%b %d %Y %I:%M%p'`, para convertir el string `'Jun 1 2005 1:33PM'`. De esa misma forma podemos especificar formatos diferentes:

```
datetime_object = datetime.strptime('06-01-2005  1:33PM', '%m-%d-%Y %I:%M%p')
datetime_object
```

```
datetime.datetime(2005, 6, 1, 13, 33)
```

Pandas tiene la *interfase* to_datetime para este tipo de operaciones que nos permite transformar campos de forma muy sencilla, por ejemplo, para trransformar la columna `FECHA_INGRESO` de los datos originales en objetos de tipo datetime podemos hacer:

```
pd.to_datetime(df['FECHA_INGRESO'].head())
```

```
3    2020-12-21
4    2020-04-22
11   2020-09-12
15   2020-08-18
22   2020-02-26
Name: FECHA_INGRESO, dtype: datetime64[ns]
```

Vean la diferencia con el tipo de datos original:

```
df['FECHA_INGRESO'].head()
```

```
3     2020-12-21
4     2020-04-22
11    2020-09-12
15    2020-08-18
22    2020-02-26
Name: FECHA_INGRESO, dtype: object
```

Esto va a funcionar perfecto cuando el campo tiene sólo datos válidos (todos se ajustan a algún formato de fecha), pero ¿qué pasa en campos en donde no todos los datos son fechas válidas?

```
pd.to_datetime(df['FECHA_DEF'].head())
```

```
ParserError: month must be in 1..12: 9999-99-99
```

ERROR!!!!! Efectívamente, pandas no puede transformar algunos datos en fechas verdaderas (porque no todos los registros tienen una fecha de defunción válida). Entonces hay que decirle a Pandas qué hacer con estos registros, lo que queremos en este caso es que los registros inválidos los regrese como nulos, para eso usamos la opción `coerce`

```
pd.to_datetime(df['FECHA_DEF'].head(), 'coerce')
```

```
3    NaT
4    NaT
11   NaT
15   NaT
22   NaT
Name: FECHA_DEF, dtype: datetime64[ns]
```

Listo, los registros que no se pueden convertir en fechas ahopra regresan `NaT` (Not a Time) en lugar de error.

Con esto en realidad ya es muy simple convertir toda una columna en tipo fecha:

```
df['FECHA_INGRESO'] = pd.to_datetime(df['FECHA_INGRESO'])
df['FECHA_INGRESO'].head()
```

```
3    2020-12-21
4    2020-04-22
11   2020-09-12
15   2020-08-18
22   2020-02-26
Name: FECHA_INGRESO, dtype: datetime64[ns]
```

Hasta aquí hemos cubierto más o menos todo el pre-proceso de los datos. Claro no vimos todas las columnas, sólo nos fijamos en algunas, pero eso basta para darnos una buena idea de cómo se hacen las demás.

### 2.4.1 Tarea

Sustituyan los valores de la columna `TIPO_PACIENTE` por sus valores en el catálogo correspondiente

# 3 Automatización

## 3.1 Función de preproceso

En el taller anterior vimos toda una serie de pasos para preprocesar los datos de COVUD-19. En esta actividad lo único que vamos a hacer es definir un par de funciones que realizan todo el flujo de preproceso. De esta forma podemos repetir todo el procedimiento de forma fácil.

```
import os # hablar con el sistema operativo
import glob # listar directorios y ese tipo de operaciones
import itertools # herramientas para iterar objetos
from pathlib import Path # manipular rutas a directorios
import zipfile # comprimir y descomprimir archivos
import numpy as np # operaciones vectorizadas
import pandas as pd # DataFrames
from datetime import timedelta, date, datetime # Manejar fechas
import openpyxl # leer/escribir archivos de exel
import requests # Hablar con direcciones web
import logging
```

## 3.2 Bajar y guardar datos

```
def bajar_datos_salud(directorio_datos='data/', fecha='10-01-2022'):
    '''
        Descarga el archivo de datos y los diccionarios para la fecha solicitada.
    '''
    fecha = datetime.strptime(fecha, "%d-%m-%Y")
    url_salud_historicos = 'http://datosabiertos.salud.gob.mx/gobmx/salud/datos_abiertos/h
    archivo_nombre = f'{fecha.strftime("%y%m%d")}COVID19MEXICO.csv.zip'
    archivo_ruta = os.path.join(directorio_datos, archivo_nombre)
    url_diccionario = 'http://datosabiertos.salud.gob.mx/gobmx/salud/datos_abiertos/diccio
    diccionario_ruta = os.path.join(directorio_datos, 'diccionario.zip')
    if os.path.exists(archivo_ruta):
```

```
        logging.debug(f'Ya existe {archivo_nombre}')
    else:
        print(f'Bajando datos {fecha.strftime("%d.%m.%Y")}')
        url_dia = "{}/{}/datos_abiertos_covid19_{}.zip".format(fecha.strftime('%Y'),
                                                               fecha.strftime('%m'),
                                                               fecha.strftime('%d.%m.%Y')
        url = url_salud_historicos + url_dia
        r = requests.get(url, allow_redirects=True)
        open(archivo_ruta, 'wb').write(r.content)
        r = requests.get(url_diccionario, allow_redirects=True)
        open(diccionario_ruta, 'wb').write(r.content)
        with zipfile.ZipFile(diccionario_ruta, 'r') as zip_ref:
          zip_ref.extractall(directorio_datos)
```

## 3.3 Preprocesar

```
def carga_datos_covid19_MX(data_dir = 'data/', fecha='210505', resolver_claves='si_no_bina
    """
        Lee en un DataFrame el CSV con el reporte de casos de la Secretaría de Salud de Mé
        también lee el diccionario de datos que acompaña a estas publicaciones para prepar
        de generar columnas binarias para datos con valores 'SI', 'No'.

        **Nota**: En esta versión la ruta esta y nombre de los archivos es fija. Asumimos
        donde se encuentran todos los archivos.

        **Nota 2**: Por las actualizaciones a los formatos de datos, esta función sólo va

        resolver_claves: 'sustitucion', 'agregar', 'si_no_binarias', 'solo_localidades'. R
        diccionario de datos y los catálogos. 'sustitucion' remplaza los valores en las co
        crea nuevas columnas. 'si_no_binarias' cambia valores SI, NO, No Aplica, SE IGNORA

    """
    fecha_formato = '201128'
    nuevo_formato = True
    fecha_carga = pd.to_datetime(fecha, yearfirst=True)
    if fecha_carga < datetime.strptime('20-11-28', "%y-%m-%d"):
      raise ValueError('La fecha debe ser posterior a 20-11-28.')

    catalogos=f'{data_dir}{fecha_formato} Catalogos.xlsx'
```

```
descriptores=f'{data_dir}{fecha_formato} Descriptores.xlsx'
data_file = os.path.join(data_dir, f'{fecha}COVID19MEXICO.csv.zip')
print(data_file)
df = pd.read_csv(data_file, dtype=object, encoding='latin-1')
if entidad is not None:
  df = df[df['ENTIDAD_RES'] == entidad]
# Hay un error y el campo OTRA_COMP es OTRAS_COMP según los descriptores
df.rename(columns={'OTRA_COM': 'OTRAS_COM'}, inplace=True)
# Asignar clave única a municipios
df['MUNICIPIO_RES'] = df['ENTIDAD_RES'] + df['MUNICIPIO_RES']
df['CLAVE_MUNICIPIO_RES'] = df['MUNICIPIO_RES']
# Leer catalogos
nombres_catalogos = ['Catálogo de ENTIDADES',
                     'Catálogo MUNICIPIOS',
                     'Catálogo RESULTADO',
                     'Catálogo SI_NO',
                     'Catálogo TIPO_PACIENTE']
if nuevo_formato:
    nombres_catalogos.append('Catálogo CLASIFICACION_FINAL')
    nombres_catalogos[2] = 'Catálogo RESULTADO_LAB'

dict_catalogos = pd.read_excel(catalogos,
                           nombres_catalogos,
                           dtype=str,
                           engine='openpyxl')

entidades = dict_catalogos[nombres_catalogos[0]]
municipios = dict_catalogos[nombres_catalogos[1]]
tipo_resultado = dict_catalogos[nombres_catalogos[2]]
cat_si_no = dict_catalogos[nombres_catalogos[3]]
cat_tipo_pac = dict_catalogos[nombres_catalogos[4]]
# Arreglar los catálogos que tienen mal las primeras líneas
dict_catalogos[nombres_catalogos[2]].columns = ["CLAVE", "DESCRIPCIÓN"]
dict_catalogos[nombres_catalogos[5]].columns = ["CLAVE", "CLASIFICACIÓN", "DESCRIPCIÓN

if nuevo_formato:
    clasificacion_final = dict_catalogos[nombres_catalogos[5]]


# Resolver códigos de entidad federal
cols_entidad = ['ENTIDAD_RES', 'ENTIDAD_UM', 'ENTIDAD_NAC']
```

```
df['CLAVE_ENTIDAD_RES'] = df['ENTIDAD_RES']
df[cols_entidad] = df[cols_entidad].replace(to_replace=entidades['CLAVE_ENTIDAD'].valu
                                            value=entidades['ENTIDAD_FEDERATIVA'].value

# Construye clave unica de municipios de catálogo para resolver nombres de municipio
municipios['CLAVE_MUNICIPIO'] = municipios['CLAVE_ENTIDAD'] + municipios['CLAVE_MUNICI

# Resolver códigos de municipio
municipios_dict = dict(zip(municipios['CLAVE_MUNICIPIO'], municipios['MUNICIPIO']))
df['MUNICIPIO_RES'] = df['MUNICIPIO_RES'].map(municipios_dict.get)

# Resolver resultados
if nuevo_formato:
    df.rename(columns={'RESULTADO_LAB': 'RESULTADO'}, inplace=True)
    tipo_resultado['DESCRIPCIÓN'].replace({'POSITIVO A SARS-COV-2': 'Positivo SARS-CoV

tipo_resultado = dict(zip(tipo_resultado['CLAVE'], tipo_resultado['DESCRIPCIÓN']))
df['RESULTADO'] = df['RESULTADO'].map(tipo_resultado.get)
clasificacion_final = dict(zip(clasificacion_final['CLAVE'], clasificacion_final['CLAS
df['CLASIFICACION_FINAL'] = df['CLASIFICACION_FINAL'].map(clasificacion_final.get)
# Resolver datos SI - NO

# Necesitamos encontrar todos los campos que tienen este tipo de dato y eso
# viene en los descriptores, en el campo FORMATO_O_FUENTE
descriptores = pd.read_excel(f'{data_dir}201128 Descriptores_.xlsx',
                             index_col='Nº',
                             engine='openpyxl')
descriptores.columns = list(map(lambda col: col.replace(' ', '_'), descriptores.column
descriptores['FORMATO_O_FUENTE'] = descriptores.FORMATO_O_FUENTE.str.strip()

datos_si_no = descriptores.query('FORMATO_O_FUENTE == "CATÁLOGO: SI_ NO"')
cat_si_no['DESCRIPCIÓN'] = cat_si_no['DESCRIPCIÓN'].str.strip()

campos_si_no = datos_si_no.NOMBRE_DE_VARIABLE
nuevos_campos_si_no = campos_si_no

if resolver_claves == 'agregar':
    nuevos_campos_si_no = [nombre_var + '_NOM' for nombre_var in campos_si_no]
elif resolver_claves == 'si_no_binarias':
    nuevos_campos_si_no = [nombre_var + '_BIN' for nombre_var in campos_si_no]
    cat_si_no['DESCRIPCIÓN'] = list(map(lambda val: 1 if val == 'SI' else 0, cat_si_no
```

```
    df[nuevos_campos_si_no] = df[datos_si_no.NOMBRE_DE_VARIABLE].replace(
                                                to_replace=cat_si_no['CLAVE'].values,
                                                value=cat_si_no['DESCRIPCIÓN'].values)

    # Resolver tipos de paciente
    cat_tipo_pac = dict(zip(cat_tipo_pac['CLAVE'], cat_tipo_pac['DESCRIPCIÓN']))
    df['TIPO_PACIENTE'] = df['TIPO_PACIENTE'].map(cat_tipo_pac.get)

    df = procesa_fechas(df)

    return df

def procesa_fechas(covid_df):
    df = covid_df.copy()

    df['FECHA_INGRESO'] = pd.to_datetime(df['FECHA_INGRESO'])
    df['FECHA_SINTOMAS'] = pd.to_datetime(df['FECHA_SINTOMAS'])
    df['FECHA_DEF'] = pd.to_datetime(df['FECHA_DEF'], 'coerce')
    df['DEFUNCION'] = (df['FECHA_DEF'].notna()).astype(int)
    df['EDAD'] = df['EDAD'].astype(int)

    df.set_index('FECHA_INGRESO', drop=False, inplace=True)
    df['AÑO_INGRESO'] = df.index.year
    df['MES_INGRESO'] = df.index.month
    df['DIA_SEMANA_INGRESO'] = df.index.weekday
    df['SEMANA_AÑO_INGRESO'] = df.index.week
    df['DIA_MES_INGRESO'] = df.index.day
    df['DIA_AÑO_INGRESO'] = df.index.dayofyear

    return df
```

## 3.4 Bajar y preprocesar usando nuestras funciones

```
ayer = datetime.now() - timedelta(2)
bajar_datos_salud(fecha=ayer.strftime('%d-%m-%Y'))
df = carga_datos_covid19_MX(fecha=ayer.strftime('%y%m%d'), entidad='09')
df
```

```
Bajando datos 18.01.2022
```

```
data/220118COVID19MEXICO.csv.zip
```

```
/tmp/ipykernel_3563/19327198.py:132: FutureWarning: weekofyear and week have been deprecated
  df['SEMANA_AÑO_INGRESO'] = df.index.week
```

| FECHA_INGRESO | FECHA_ACTUALIZACION | ID_REGISTRO | ORIGEN | SECTOR | ENTIDAD_ |
|---|---|---|---|---|---|
| 2020-07-06 | 2022-01-18 | z12d63 | 2 | 12 | CIUDAD DE |
| 2020-09-23 | 2022-01-18 | z13788 | 1 | 12 | CIUDAD DE |
| 2020-06-15 | 2022-01-18 | z2b144 | 2 | 12 | CIUDAD DE |
| 2020-12-21 | 2022-01-18 | z526b3 | 2 | 12 | CIUDAD DE |
| 2020-04-22 | 2022-01-18 | z3d1e2 | 2 | 12 | CIUDAD DE |
| ... | ... | ... | ... | ... | ... |
| 2021-10-11 | 2022-01-18 | m00073e | 2 | 12 | MÉXICO |
| 2021-10-13 | 2022-01-18 | m030623 | 2 | 12 | MÉXICO |
| 2021-10-13 | 2022-01-18 | m049633 | 2 | 12 | MÉXICO |
| 2021-10-13 | 2022-01-18 | m160d02 | 2 | 12 | MÉXICO |
| 2021-10-14 | 2022-01-18 | m0da9ec | 2 | 12 | MÉXICO |

## 3.5 Guardando el resultado

Listo, con nuestras funciones tenemos ya nuestros datos preprocesados, ahora vamos a guardarlos para poder utlizarlos rápidamente en otros notebooks. En general tenemos muchas opciones para guardar los datos, csv, por ejemplo. En esta ocasión vamos a usar un formato nativo de Python el pickle, que es una forma de *serializar* un objeto de Python. Pandas nos provee una función para guardar directamente un dataframe como pickle:

```
df.to_pickle("data/datos_covid_ene19.pkl")
```

En la documentación de to_pickle pueden ver las opcioones completas.

# Part II

# Geoinformática en R

Esta parte del libro cubre el manejo de datos espaciales utilizando R

**EN CONSTRUCCIÓN**

# 4 Introducción a R

**EN CONSTRUCCIÓN**

# 5 Summary

In summary, this book has no content whatsoever.

# References